大数据简介

摘要

- 大数据背景
- 大数据定义
- 大数据技术
- 大数据应用
- 金融大数据

摘要

- 大数据背景
- 大数据定义
- 大数据技术
- 大数据应用
- 金融大数据

大数据背景

我们正处在信息爆炸的年代!

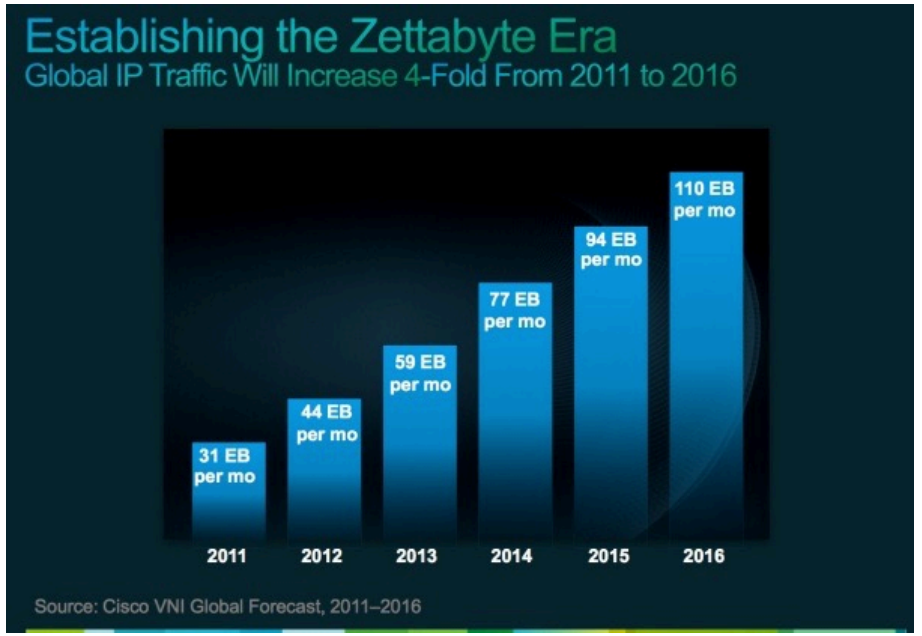
2000年　数字数据只占全球数据量的1/4

2007年　所有数据中只有7%是存储在报纸、书籍、图片等媒介上的模拟数据，其余93%全是数字数据（二进制数据）

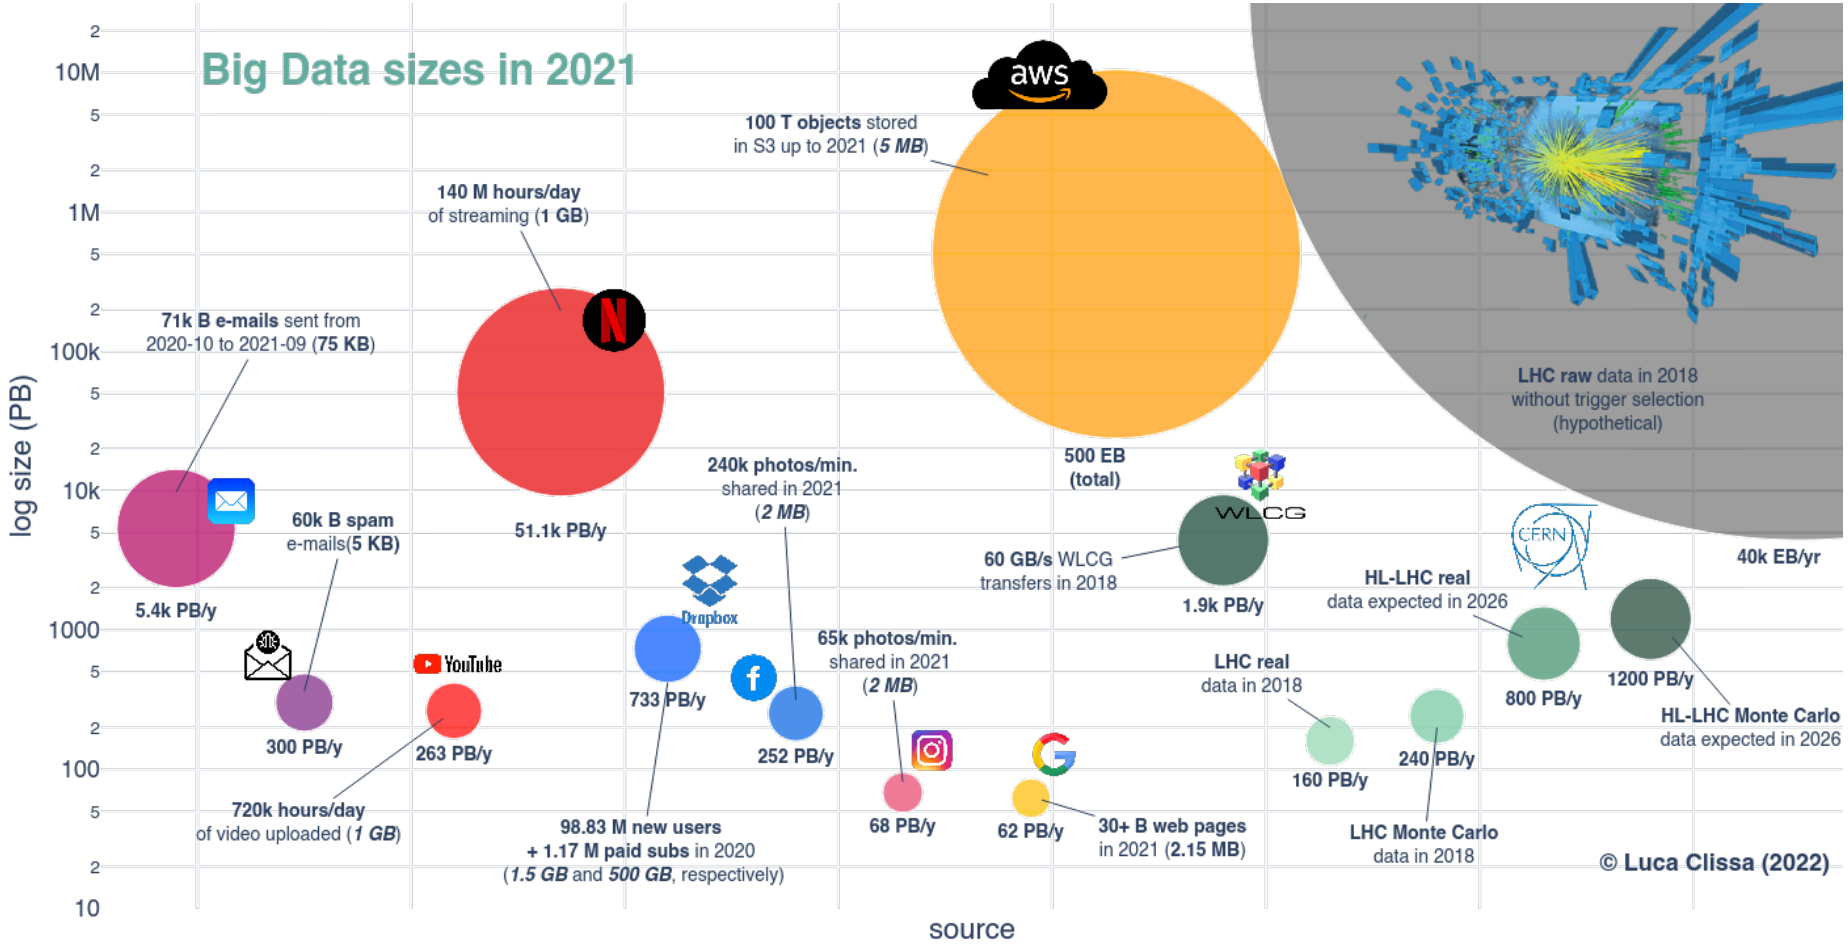
Google 2008年单日数据处理量超过 24PB

新浪微博 2011年全年数据量370T

淘宝网 2019年双11单日数据处理量970PB

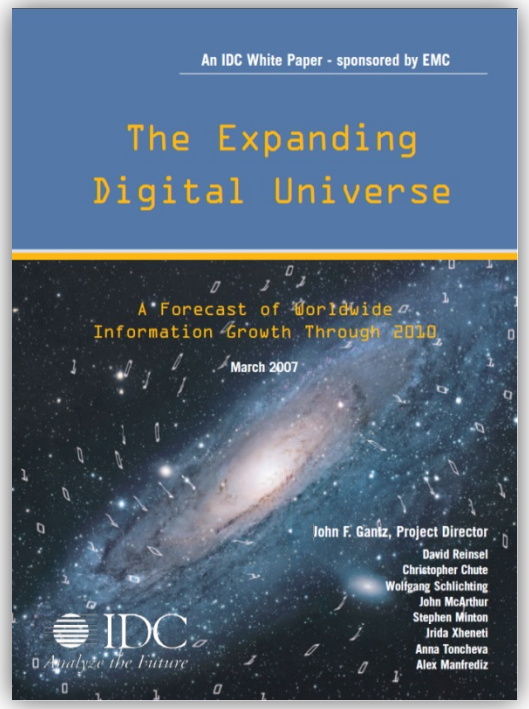


大数据背景


Big Data sizes in 2021
log size (PB)
source
100 T objects stored in S3 up to 2021 (5 MB)
500 EB (total)
140 M hours/day of streaming (1 GB)
51.1k PB/y
71k B e-mails sent from 2020-10 to 2021-09 (75 KB)
5.4k PB/y
60k B spam e-mails(5 KB)
300 PB/y
720k hours/day of video uploaded (1 GB)
263 PB/y
240k photos/min. shared in 2021 (2 MB)
252 PB/y
733 PB/y
98.83 M new users + 1.17 M paid subs in 2020 (1.5 GB and 500 GB, respectively)
65k photos/min. shared in 2021 (2 MB)
68 PB/y
62 PB/y
30+ B web pages in 2021 (2.15 MB)
60 GB/s WLCG transfers in 2018
1.9k PB/y
LHC raw data in 2018 without trigger selection (hypothetical)
40k EB/yr
LHC real data in 2018
160 PB/y
LHC Monte Carlo data in 2018
240 PB/y
HL-LHC real data expected in 2026
800 PB/y
1200 PB/y
HL-LHC Monte Carlo data expected in 2026
© Luca Clissa (2022)

大数据背景

- IDC研究报告《Data Universe Study》：提出“数据宇宙”概念来描述大数据





全世界数据量将从2009年的0.8ZB增长到2025年的175ZB!

大数据背景

- 根据IBM前首席执行官郭士纳的观点，IT领域每隔十五年就会迎来一次重大变革。

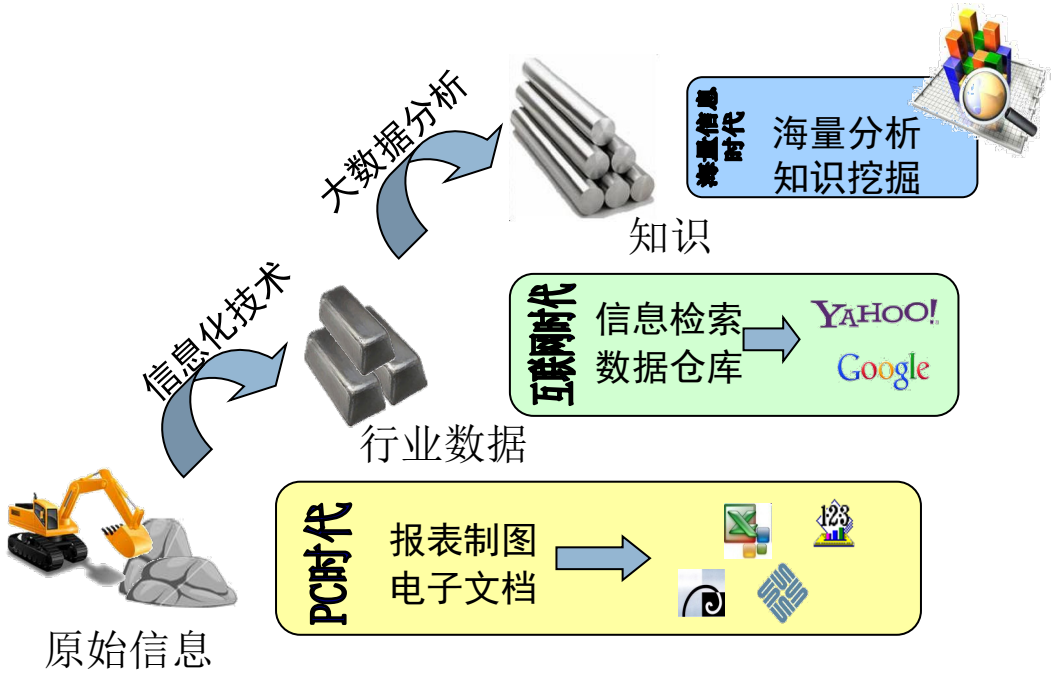




大数据背景

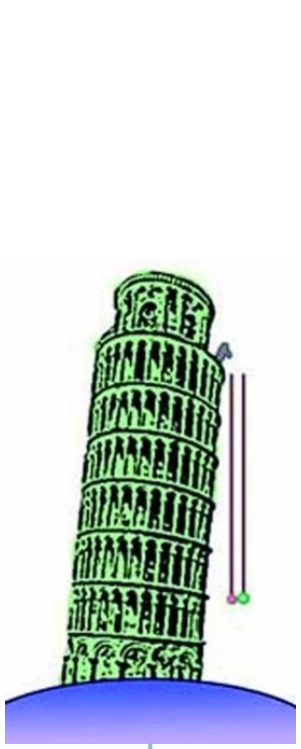
- 三次信息化浪潮

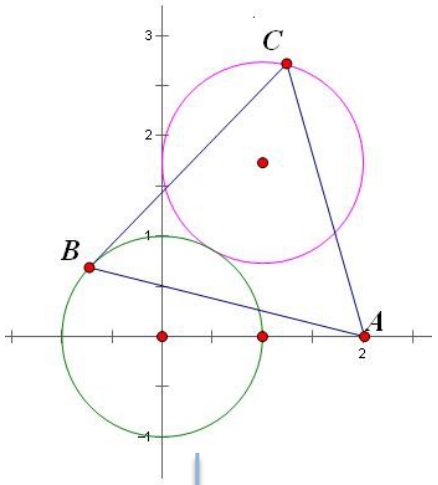
信息化浪潮	发生时间	标志	解决问题	代表企业
第一次浪潮	1980年前后	个人计算机	信息处理	Intel、AMD、IBM、苹果、微软、联想、戴尔、惠普等
第二次浪潮	1995年前后	互联网	信息传输	雅虎、谷歌、阿里巴巴、百度、腾讯等
第三次浪潮	2010年前后	物联网、云计算和大数据	信息爆炸	将涌现出一批新的市场标杆企业



数据科学（Data Science）

- Jim Gray：“数据密集型科学发现”将成为科学研究的第四范式。



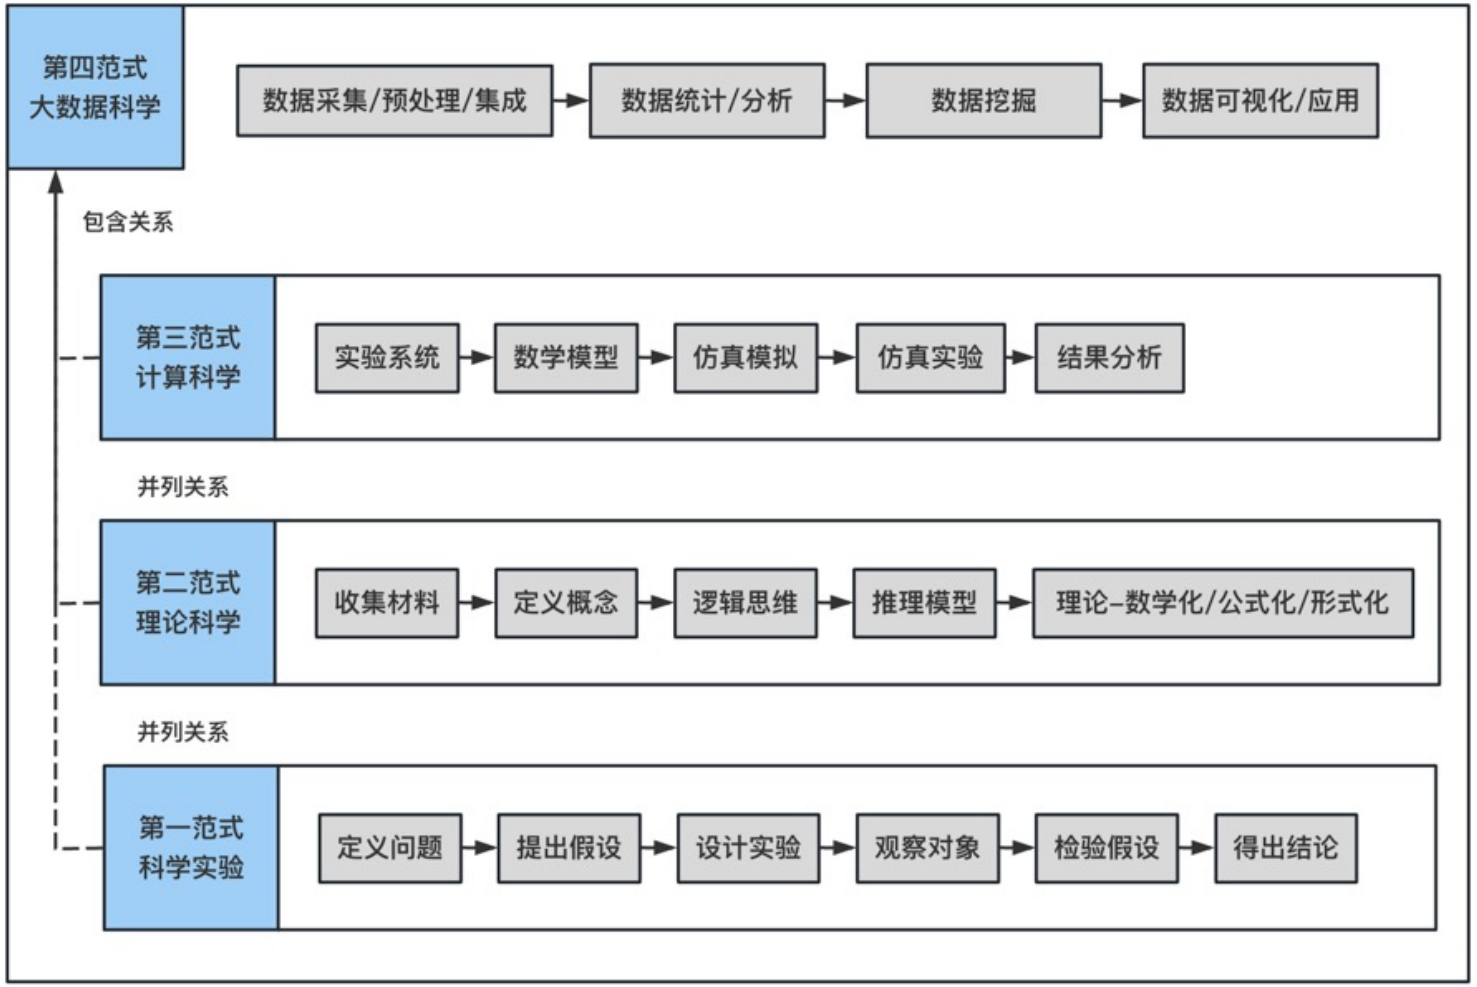






实验科学　理论科学　计算科学　数据科学

数据科学（Data Science）



第四范式研究框架是由科学实验，理论模型或算法，计算机模拟和密集型数据处理组成。

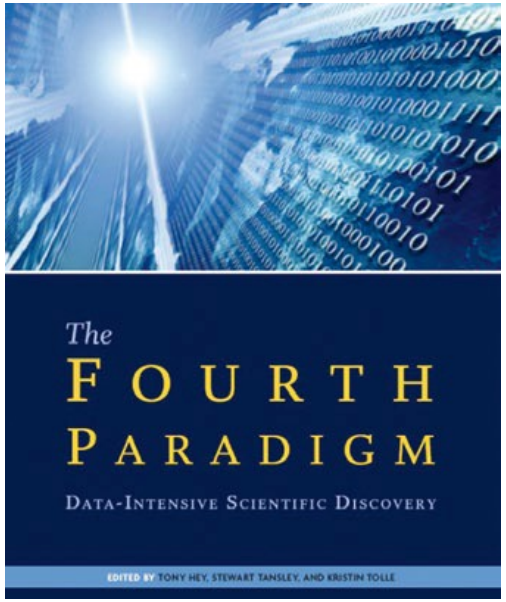
用计算机技术解决复杂数学计算问题，建立数学模型，设计求解方法，通过计算机编程实现。

通过观察自然和社会现象内部规律，以获得和检验科学结论的一种方法。

通过观察自然和社会现象内部规律，以获得和检验科学结论的一种方法。

数据科学（Data Science）

- 李国杰，《大数据研究的科学价值》，中国计算机学会通讯，2012年9月。
  - 计算机科学是关于算法的科学，数据科学是关于数据的科学。





大数据研究的科学价值

李国杰
中国科学院计算技术研究所

关键词：大数据 数据科学 第四范式

近年来，“大数据”已经成为科技界和企业界关注的热点。2012年3月，美国奥巴马政府宣布投资2亿美元启动“大数据研究和发展计划”，这是继1993年美国宣布“信息高速公路”计划后的又一次重大科技发展部署。美国政府认为大数据是“未来的新石油”，将“大数据研究”上升为国家意志，对未来的科技与经济发展必将带来深远影响。一个国家拥有数据的规模和运用数据的能力将成为综合国力的重要组成部分，对数据的占有和控制也将成为国家间和企业间新的争夺焦点。

与大数据的经济价值相比，大数据研究的科学价值似乎还没有引起足够的重视。本文试图对基于大数据的科学研究（包括自然科学、工程科学和社会科学）谈几点粗浅的认识，希望引起有关领域科技人员的争鸣。

推动大数据的动力主要是企业经济效益

数据是与自然资源、人力资源一样重要的战略资源，隐含巨大的经济价值，已引起科技界和和企业界的高度重视。如果有效地组织和使用大数据，将对经济发展产生巨大的推动作用，孕育出前所未有的机遇。奥莱利（O'Reilly）公司断言：“数据是下一个‘Intel inside’，未来属于将数据转换成产品的公司和人们。”

基因组学、蛋白组学、天体物理学和脑科学等都是以数据为中心的学科。这些领域的基础研究产生的数据越来越多，例如，用电子显微镜重建大脑中的突触网络，1立方毫米大脑的图像数据就超过1PB。但是，近年来大数据的飙升主要还是来自人们的日常生活，特别是互联网公司的服务。据IDC公司统计，2011年全球被创建和被复制的数据总量为1.8ZB（10^{21}），其中75%来自于个人（主要是图片、视频和音乐），远远超过人类有史以来所有印刷材料的数据总量（200PB）。谷歌公司通过大规模集群和MapReduce软件，每个月处理的数据量超过400PB；百度每天大约要处理几十PB数据；Facebook注册用户超过10亿，每月上传的照片超过10亿张，每天生成300TB以上的日志数据；淘宝网会员超过3.7亿，在线商品超过8.8亿，每天交易数千万笔，产生约20TB数据；雅虎的总存储容量超过100PB。传感网和物联网的蓬勃发展是大数据的又一推动力，各个城市的视频监控每时每刻都在采集巨量的流媒体数据。工业设备的监控也是大数据的重要来源。例如，劳斯莱斯公司对全世界数以万计的飞机引擎进行实时监控，每年传送PB量级的数据。

数据为王的大数据时代已经到来，战略需求也发生了重大转变：企业关注的重点转向数据，计算机行业正在转变为真正的信息行业，从追求计算速度转变为大数据处理能力，软件也将从编程为主转变为以数据为中心。采用大数据处理方法，生物制药、新材料研制生产的流程会发生革命性的变化，可以通过数据处理能力极高的计算机并行处理，同时进行大批量的仿真、比较和筛选，大大提高科研

挑战

储存 Storing

每天几百 GB、 几 TB 的资料，且持续成长中

计算 Processing

在收集数据的同时做必要的前置处理 (pre-processing)
并区分数据处理的优先等级 (prioritizing)

管理 Managing

如何有效的避免因硬件毁坏所导致的资料损毁

分析 Analyzing

如何从中挖掘出所关注事件的 pattern 或 behavior

摘要

- 大数据背景
- 大数据定义
- 大数据技术
- 大数据应用
- 金融大数据

什么是数据?

半结构化/非结构化数据

Web Clickstream



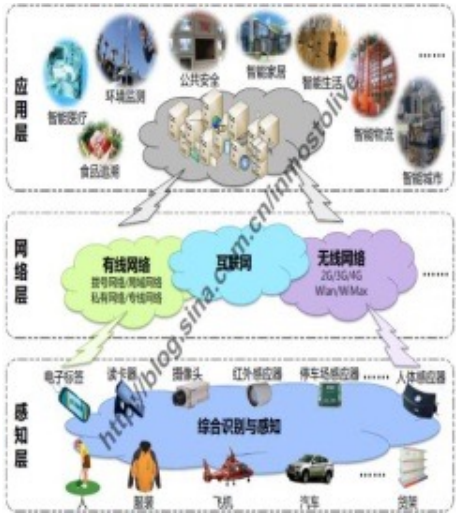
DOC / Media



Social Media



Machine / Sensor



Call Log



Apps







什么是大数据?

何为大? — 数据度量

1Byte = 8 Bit

1KB = 1,024 Bytes

1MB = 1,024 KB = 1,048,576 Bytes

1GB = 1,024 MB = 1,048,576 KB = 1,073,741,824 Bytes

1TB = 1,024 GB = 1,048,576 MB = 1,099,511,627,776 Bytes

1PB = 1,024 TB = 1,048,576 GB =1,125,899,906,842,624 Bytes

1EB = 1,024 PB = 1,048,576 TB = 1,152,921,504,606,846,976 Bytes

1ZB = 1,024 EB = 1,180,591,620,717,411,303,424 Bytes

1YB = 1,024 ZB = 1,208,925,819,614,629,174,706,176 Bytes

什么是大数据?

- 数据没有办法在可容忍的时间下使用常规软件方法完成存储、管理和处理任务

《红楼梦》含标点87万字（不含标点853509字）

每个汉字占两个字节：1汉字=16bit = 2*8位=2bytes

1GB 约等于 671部红楼梦；1TB 约等于 631,903 部；1PB 约等于 647,068,911部

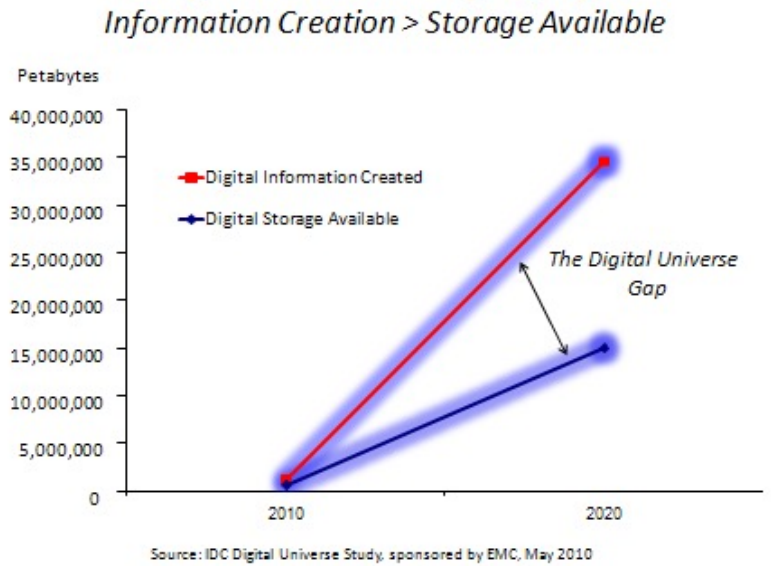
美国国会图书馆藏书（151,785,778册）（2011年4月：收录数据235TB ）

中国国家图书馆：2631万册

1EB = 4000倍 美国国会图书馆存储的信息量

600美元的硬盘就可以存储全世界所有的歌曲

MGI估计,全球企业 2010 年在硬盘上存储了超过 7EB(1EB 等于 10 亿 GB) 的新数据，同时，消费者在 PC 和笔记本等设备上存储了超过 6EB 新数据





什么是大数据?

- 数据存储访问能力大幅落后于数据增长速度
  - 磁盘容量增长远远快过存储访问带宽和延迟：80年代中期，数十MB到今天1-2TB，增长10万倍，而延迟仅仅提高2倍，带宽仅仅提高50倍!
  - 100TB数据顺序读一遍需要多少时间?

    假设硬盘读取访问速率128MB/s

    1TB 约2.17小时

    100TB约217小时（9天！）

    即使使用百万元高速磁盘阵列（800MB/s），仍需1.5天!



大数据定义

- Wiki: Big data is a collection of data sets so large and complex that it becomes difficult to process using on-hand database management tools.

- 大数据意指一个超大的、难以用现有常规的数据库管理技术和工具处理的数据集。



大数据定义

- IDC报告： Big data technologies describe a new generation of technologies and architectures, designed to economically extract value from very large volumes of a wide variety of data, by enabling high-velocity capture, discovery, and/or analysis.

- 大数据技术描述了一种新一代技术和构架，用于以很经济的方式、以高速的捕获、发现和分析技术，从各种超大规模的数据中提取价值。

大数据带来的思维变革

更杂
不是精确性而是混杂性

更好
不是因果关系而是相关关系

更多
不是随机样本而是全部数据



大数据带来的思维变革（更多）

小数据时代 → 大数据时代

人口大普查 全数据模式	随机采样 样本模式	大数据应用 全数据模式

- 是指在国家统一规定的时间内，按照统一的方法、统一的项目、统一的调查表和统一的标准时点，对全国人口普遍地、逐户逐人地进行的一次性调查登记；
- 主要特点是调查组织高度集中性，普查对象的全面完整性；
- 人口大普查耗时耗费，一般来讲是十年一次，新中国成立以来共进行了7次人口大普查；
- 人口大普查是一种典型的全数据模式。

大数据带来的思维变革（更多）

小数据时代 → 大数据时代

人口大普查 全数据模式	随机采样 样本模式	大数据应用 全数据模式

- 人口大普查是一种耗时耗费的工程，一般是以十年为单位；
- 各国每年需要进行几百次的小规模人口调查，采取随机采样分析的方式，这是一种样本模式；
- 源于实用并且很好的创新！
- 随机采样分析是小数据时代的产物。

大数据带来的思维变革（更多）

小数据时代 → 大数据时代

人口大普查 全数据模式	随机采样 样本模式	大数据应用 全数据模式

- 我们已具备了大数据的各种技术能力，思维需要转换到大数据的全数据模式：样本=全部；
- 大数据不用随机分析法这样的捷径，而采用所有数据的方法；
- 这里的“大”是相对的——相扑比赛所有数据存储还不需要一个TB，但是是所有的数据！
- 在大数据时代采用随机采样法，就像在汽车时代骑马一样，虽然特定情况下仍可采样随机采样法，但是慢慢地我们会放弃它。

大数据带来的思维变革（更杂）





从皮尺到哈勃望远镜，人类一直在追求测量的精确性，一方面源于对未知世界的认知；一方面也源于收集信息的有限性。

- 大数据的简单算法比小数据的复杂算法更有效；
  - Google的机器翻译 VS IBM的机器翻译 ；
- 纷繁的数据越多越好；
  - 大数据时代要求我们重新审视数据精确性的优略；
  - 大数据不仅让我们不再期待精确性，也让我们无法实现精确性；
  - 错误不是大数据固有的问题，而是一个需要我们去解决的问题，而且会将长期存在；
- 混杂性，不是竭力避免，而是标准途径。

大数据带来的思维变革（更好）

佛教关于因果报应的解释	哲学范畴的因果关系	舍恩伯格对大数据的相关性解释
佛教《三世因果经》主要讲：一是人的命是自己造就的；二是怎样为自己造一个好命；三是行善积德与行凶作恶干坏事的因果循环报应规律。	原因和结果是揭示客观世界中普遍联系着的事物具有先后相继、彼此制约的一对范畴。原因是指引起一定现象的现象，结果是指由于原因的作用而引起的现象。	大数据的相关关系，而不强调因果关系；（舍恩伯格），其实这个只是一种对无法探究因果的妥协，人类应该去探寻因果，因为世界存在客观的运转规律；



Kaggle，一个为所有人提供数据挖掘竞赛的公司，在一次关于二手车的数据分析比赛中得到，橙色汽车有质量问题的可能性是其它颜色汽车的一半。为什么？

探寻事物的因果关系是人类的本性，但是大数据时代可以做某种程度的妥协，可以只需要关注“是什么”，而忽略“为什么？”

大数据的5V特征

- Volume（大体量）：即可从数百TB到数十数百PB，甚至EB的规模
- Variety（多样性）：即大数据包括各种格式和形态的数据
- Velocity（时效性）：即很多大数据需要在一定的时间限度下得到及时处理
- Veracity（准确性）：即处理的结果要保证一定的准确性
- Value（大价值）：即大数据包含很多深度的价值，大数据分析挖掘和利用将带来巨大的商业价值

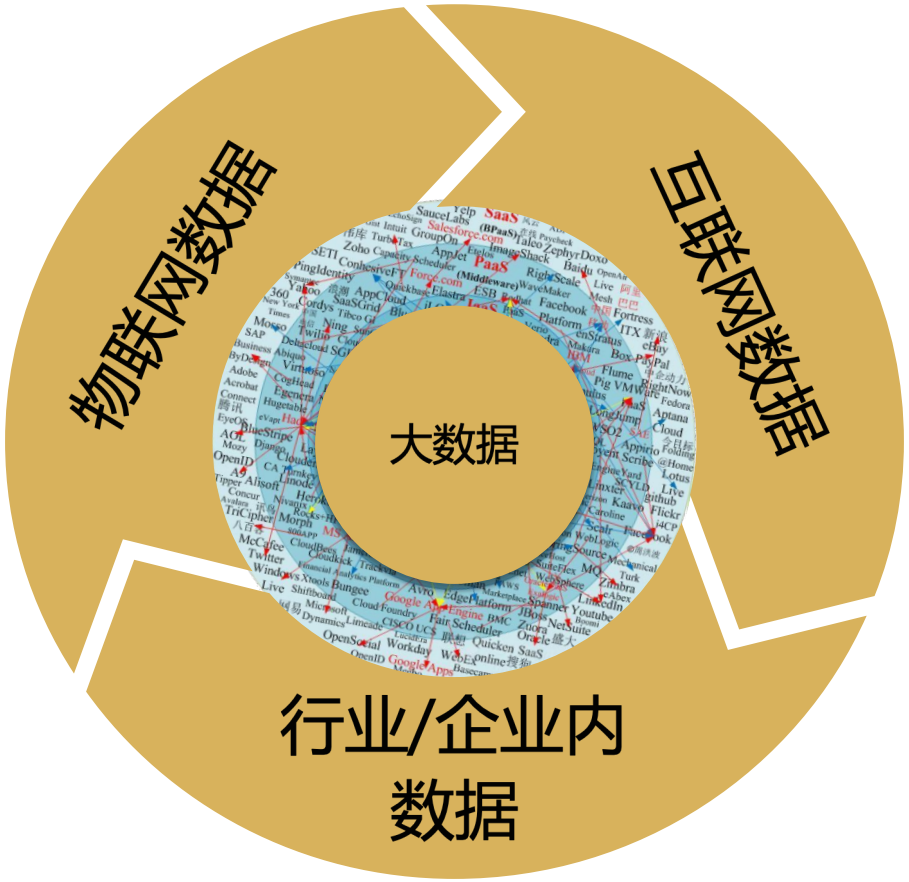
大数据的5V特征（Volume）



一般情况下，大数据是以PB、EB、ZB为单位进行计量的

- 1PB相当于50%的全美学术研究图书馆藏书信息内容
- 5EB相当于至今全世界人类所讲过的话语
- 1ZB如同全世界海滩上的沙子数量总和
- 1YB相当于7000位人类体内的微细胞总和

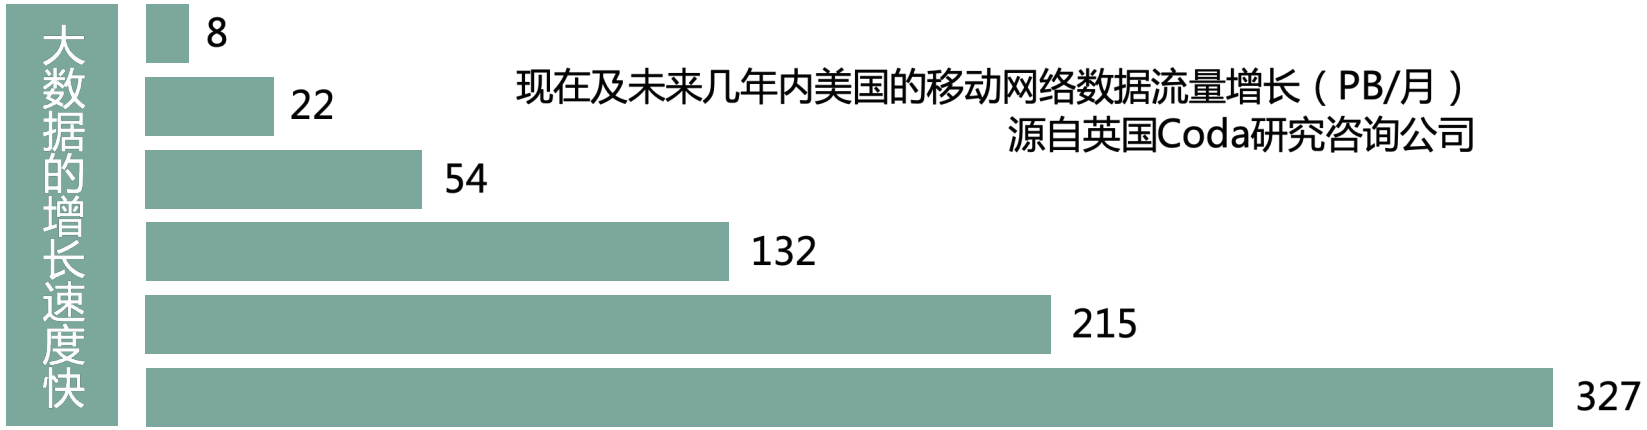
大数据的5V特征（Variety）



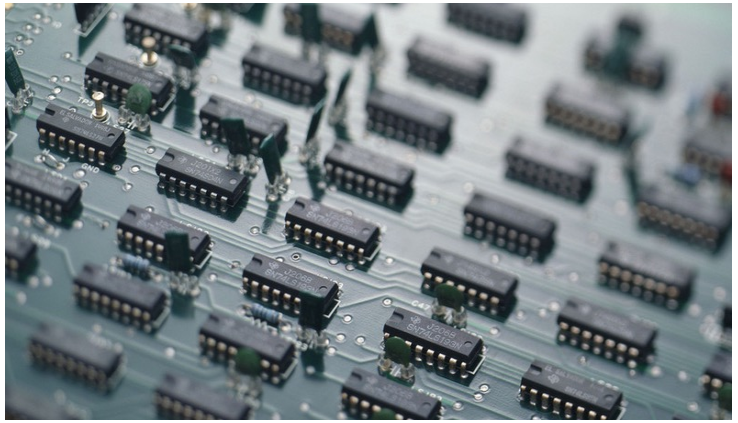
数据来源多	企业内部多个应用系统的数据、互联网和物联网的兴起，带来了微博、社交网站、传感器等多种来源。
数据类型多	保存在关系数据库中的结构化数据只占少数，70~80%的数据是如图片、音频、视频、模型、连接信息、文档等非结构化和半结构化数据。
关联性强	数据之间频繁交互，比如游客在旅行途中上传的图片和日志，就与游客的位置、行程等信息有了很强的关联性。

大数据的5V特征（Velocity）

大数据的增长速度快



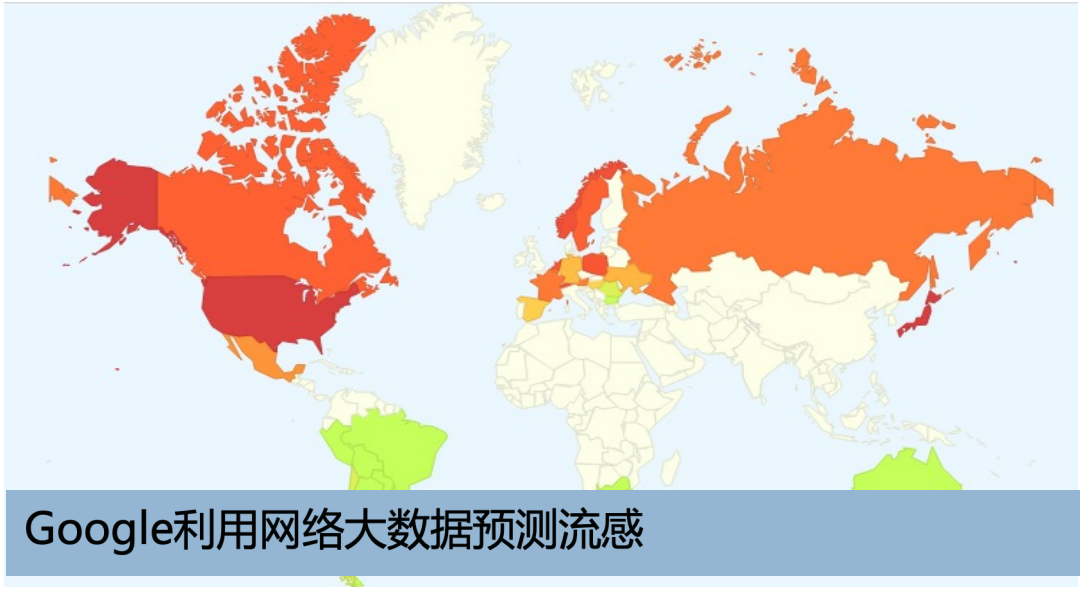
大数据的处理速度快



- 实时数据流处理的要求，是区别大数据应用和传统数据仓库技术，BI技术的关键差别之一；
- 1s 是临界点，对于大数据应用而言，必须要在1秒钟内形成答案，否则处理结果就是过时和无效的.

大数据的5V特征（Veracity）

- 大数据隐含着更准确的事实



Google利用网络大数据预测流感

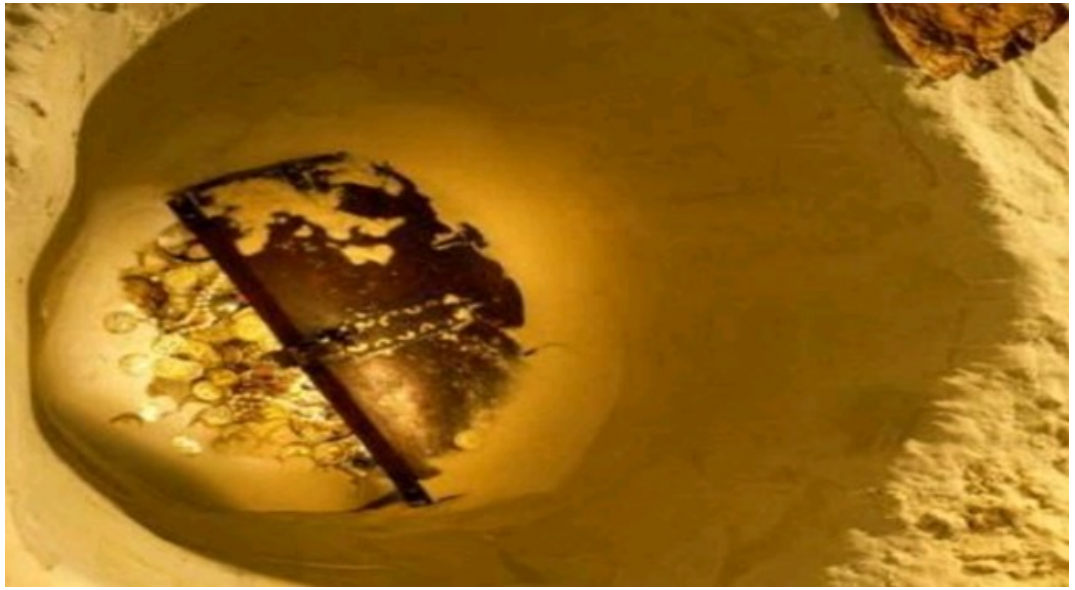


埃齐奥尼的Farecast有10万亿条数据预测机票价格

结论：大数据聚集上的简单算法能比小数据集上的复杂算法产生更好的结果！

大数据的5V特征（Value）

大数据不仅仅是技术，关键是产生价值。



- 挖掘大数据的价值类似沙里淘金，从海量数据中挖掘稀疏但珍贵的信息
- 价值密度低，是大数据的一个典型特征



大数据的类型

- 结构特征
  - 结构化数据
  - 非结构化/半结构化数据
- 获取和处理方式
  - 动态（流式/增量式/线上）/实时数据
  - 静态（线下数据）/非实时数据
- 关联特征
  - 无关联/简单关联数据（键值记录型数据）
  - 复杂关联数据（图数据）

大数据问题的特点和研究原则

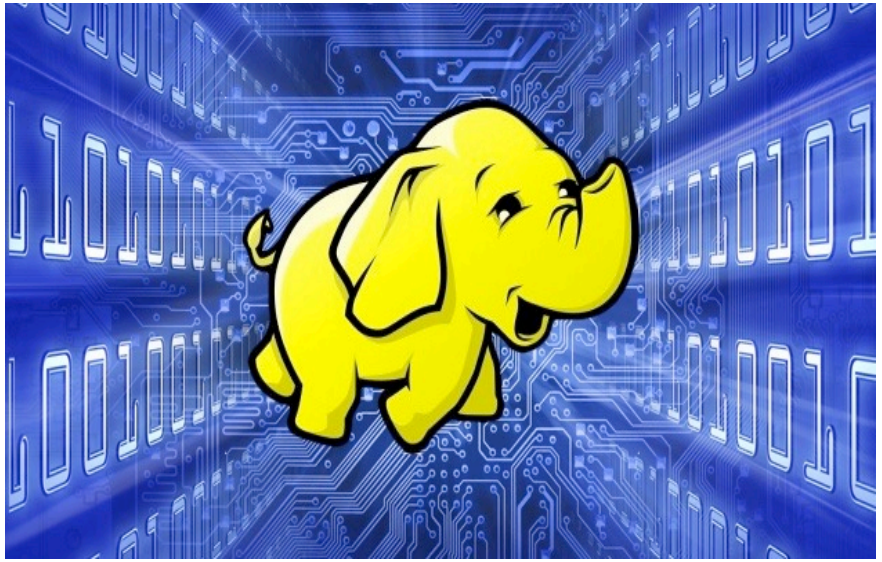
- 基本特点
  - 大数据来自应用行业，具有极强的行业应用需求特性
  - 数据规模极大，达到PB甚至EB量级，超过任何传统数据库系统的处理能力
  - 大数据处理给传统计算技术带来极大挑战，大多数传统算法在面向大数据处理时都面临问题，需要重写
- 基本原则
  - 应用需求为导向：以行业应用问题和需求为出发点
  - 领域交叉为桥梁：行业、IT产业、学术界协同
  - 计算技术为支撑：研究解决涉及的计算技术问题

摘要

- 大数据背景
- 大数据定义
- 大数据技术
- 大数据应用
- 金融大数据

软件是大数据的引擎

- 和数据中心（Data Center）一样，软件是大数据的驱动力。



- 软件改变世界!

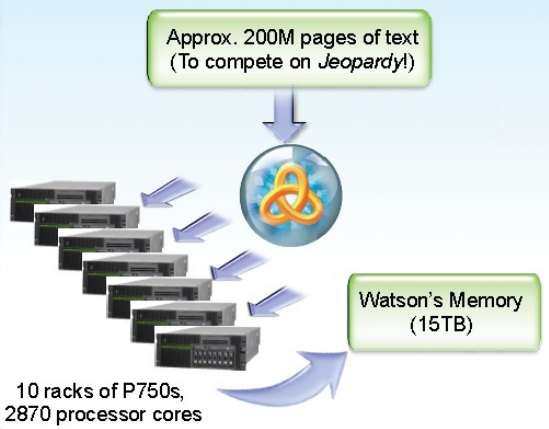


软件是大数据的引擎

Big Data and Watson

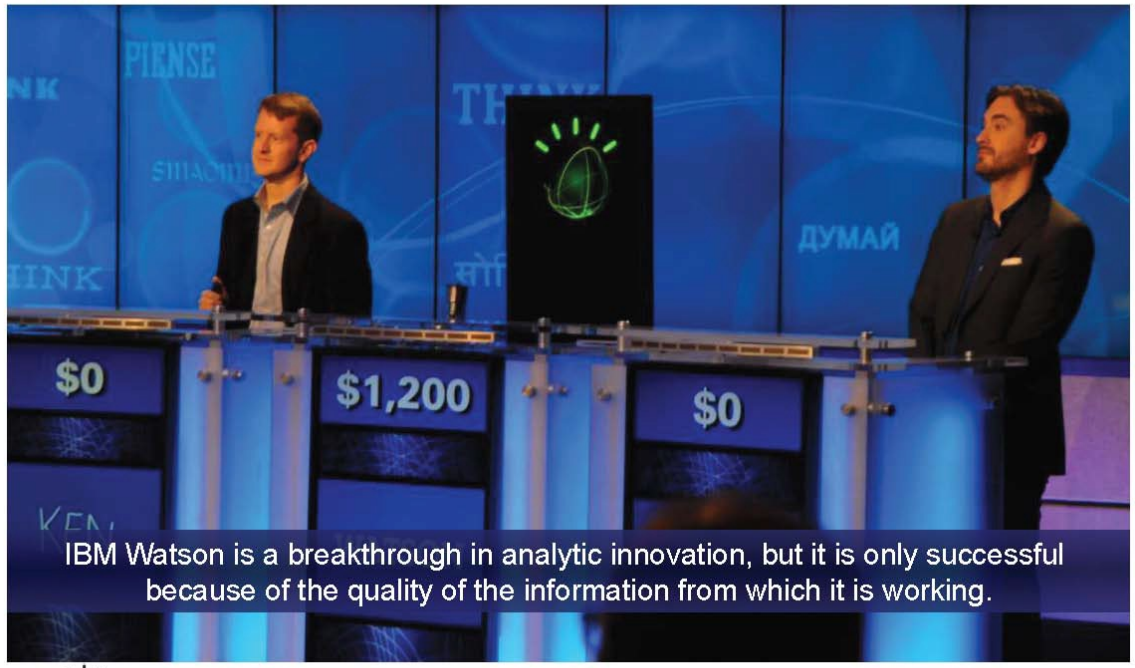
Big Data technology is used to build Watson's knowledge base

Watson used the ***Apache Hadoop*** open framework to distribute the workload for loading information into memory.



IBM

IBM Watson



©2011 BW@ IBM Corporation

软件是大数据的引擎

AlphaGo





分布式

AlphaGo Lee

- 在谷歌云上有50 TPUs在运作
- 搜索50个棋步为10000个位置/秒
- 于2016年在首尔打倒李世石



单机

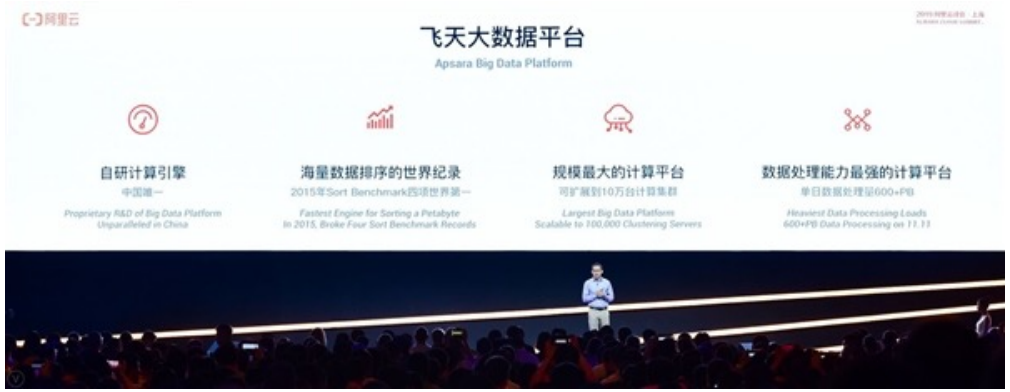
AlphaGo Master

- 在单个TPU机器上进行游戏
- AlphaGo 成为自己的老师
  它从自己的搜索里学习
- 更强大的策略 / 价值网络



软件是大数据的引擎

- 2019年7月25日，在阿里云峰会上海站上，**阿里云飞天大数据平台**正式亮相。据悉，这是中国唯一自主研发的计算引擎，也是全球集群规模最大的计算平台。



- 数据显示，目前飞天大数据平台可扩展至10万台计算集群，集群规模全球第一。单日数据处理量从2015年100PB、2016年180PB、2017年320PB，到2018年超过600PB，仅用三年时间提升5倍。

大数据研究的基本目标

- 以有效的信息技术手段和计算方法，获取、处理和分析各类应用行业的大数据，发现和提取数据的内在价值，为行业提供高附加值的应用和服务。
  - 技术手段：信息技术和计算方法
  - 核心目标：价值发现
  - 效益目标：形成高附加值行业应用

大数据研究的挑战和基本途径

- 挑战
  - 数据规模导致难以应付的存储量
  - 数据规模导致传统算法失效
  - 大数据复杂的数据关联性导致高复杂度的计算
- 基本途径
  - 寻找新算法降低计算复杂度
  - 降低大数据尺度，寻找数据尺度无关算法
  - 大数据并行化处理

大数据研究层面

- 从信息处理过程



- 从计算机技术研究与学科视角



大数据研究层面

- 从系统的观点看大数据研究层面



大数据是诸多计算技术的融合，因此需要从信息系统视角来划分大数据研究层面，形成一个基于硬件系统的软件栈。

大数据研究层面


应用层
大数据行业应用/服务层
电信/公安/商业/金融/遥感遥测/勘探/生物医药……
领域应用/服务需求和计算模型
行业用户
领域专家
应用开发层
分析工具/开发环境和工具/行业应用系统开发
应用开发者
算法层
应用算法层
社会网络,排名与推荐,商业智能,自然语言处理,生物信息
媒体分析检索, Web挖掘与检索, 3维建模与可视化计算…
基础算法层
并行化机器学习与数据挖掘算法
计算技术研究和开发者
系统层
并行编程模型与计算框架层
MapReduce, BSP, MPI, CUDA, OpenMP, 定制式,
混合式 (如MapReduce+CUDA, MapReduce+MPI)
大数据存储管理层
大数据查询(SQL, NoSQL, 实时查询, 线下分析)
大数据存储(DFS, HBase, RDFDB, MemDB, RDB)
大数据预处理
构架层
并行构架和资源平台层
集群, 众核, GPU, 混合式构架 (如集群+众核, 集群+GPU)
云计算资源与支撑平台

大数据典型和热点技术问题

- 大数据存储管理和索引查询
- 大数据计算模型和框架
- Hadoop/Spark性能优化和功能增强
- 并行化机器学习和数据挖掘算法
- 社会网络分析
- Web信息搜索和排名推荐
- 媒体分析检索
- 基于本体的语义分析与挖掘
- 大数据自然语言处理智能化应用
- 大数据可视化计算与分析

系统层

基础算法

典型/共性应用算法与技术

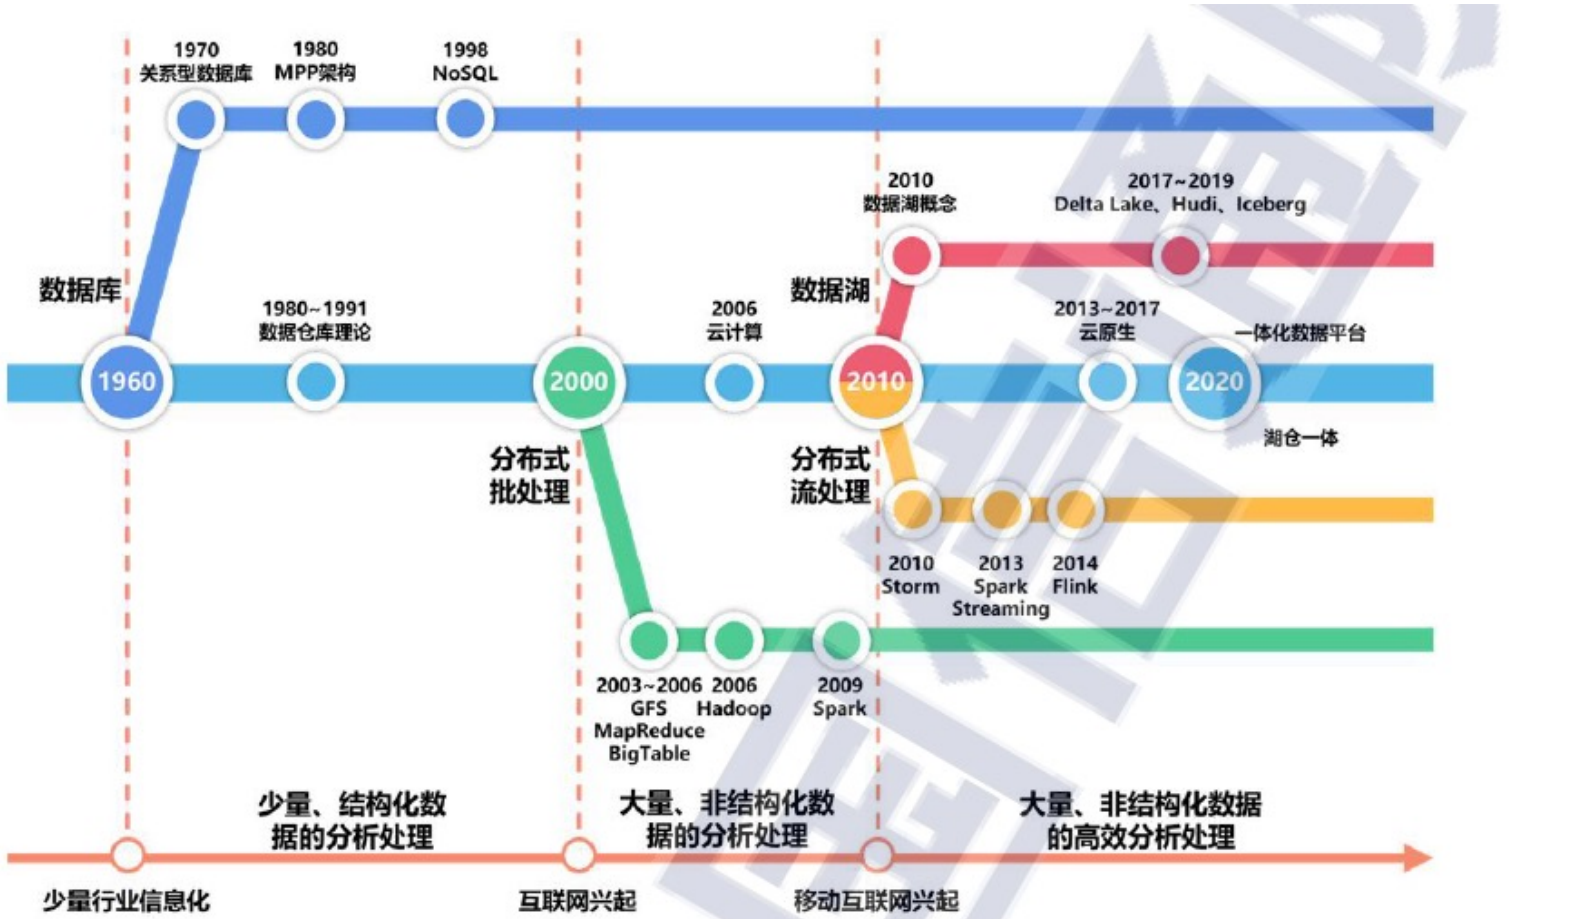
大数据涉及的关键技术

需求	技术	描述
海量数据存储技术	Hadoop，x86/MPP Map Reduce	分布式文件系统
实时数据处理技术	Streaming Data	流计算引擎
数据高速传输技术	Infini Band	服务器/存储间高速通信
搜索技术	Enterprise Search	文本检索、智能搜索、实时搜索
数据分析技术	Text Analytics Engine Visual Data Modeling	自然语言处理、文本情感分析、机器学习、聚类关联、数据模型

后Hadoop时代新的大数据计算模式和系统出现，其中尤其以内存计算为核心、集诸多计算模式之大成的Spark生态系统的出现为典型代表

- 大数据查询分析计算
- 批处理计算
- 流式计算
- 迭代计算
- 图计算
- 内存计算

数据平台技术演变



来源：中国信息通信研究院

大数据技术前瞻

- 四大挑战
  - 如何构建以数据为中心的计算体系
  - 如何满足大数据高效处理的需求
  - 如何实现多源异构大数据的可解释性分析
  - 如何形成系统化大数据治理框架与关键技术

梅宏，杜小勇，金海，等，大数据技术前瞻，大数据，2023，9(1):1-20



摘要

- 大数据背景
- 大数据定义
- 大数据技术
- 大数据应用
- 金融大数据

大数据应用

大数据应用领域

表1　大数据应用最令人瞩目领域调查结果对比

序号	2014年	2015年	2016年	2017年	2018年
1	互联网;电子商务	互联网;电子商务	互联网;电子商务	互联网;电子商务	金融
2	金融	金融	金融	健康医疗	互联网;电子商务
3	健康医疗	健康医疗	健康医疗	金融	健康医疗
4	舆情分析;情报分析	城镇化;智慧城市	城镇化;智慧城市		城镇化;智慧城市
5		社会安全;犯罪调查	舆情分析;情报分析		

表2　2020年大数据趋势专项调研结果

序号	调研项目	调研结果
1	最令人瞩目的应用领域	健康医疗、城镇化/智慧城市、金融、互联网/电子商务
2	将取得重大应用和技术突破的数据类型	视频数据、城市数据及地理数据、互联网公开数据、语音数据
3	最令人瞩目的学科和技术	人工智能、自然语言处理/知识工程、图计算
4	将取得突破性进展的技术环节	数据分析、数据语义理解、脱敏和隐私保护
5	大数据市场处于哪个阶段	稳定增长、即将快速扩张、爆发增长
6	我国大数据发展的最主要推动者	大型互联网企业、政府机构
7	在数据资源流转上的举措	会自己收集数据、会利用数据提供服务、会买数据
8	专家个人的工作重点	算法等基础技术研究、应用实践、人才教育
9	大数据的最佳拍档概念	数据科学、机器人和人工智能、智能计算和认知计算、5G

大数据商业价值

行业	数据处理方式	价值
银行／金融	•贷款、保险、发卡等多业务线数据集成分析、市场评估 •新产品风险评估 •股票等投资组合趋势分析	•增加市场份额 •提升客户忠诚度 •提高整体收入 •降低金融风险
医疗	•共享电子病历及医疗记录，帮助快速诊断 •穿戴式设备远程医疗	•改善诊疗质量 •加快诊疗速度
制造／高科技	•产品故障、失效综合分析 •专利记录检索 •智能设备全球定位，位置服务	•优化产品设计、制造 •降低保修成本 •加快问题解决
能源	•勘探、钻井等传感器阵列数据集中分析	•降低工程事故风险 •优化勘探过程
互联网／Web2.0	•在线广告投放 •商品评分、排名 •社交网络自动匹配 •搜索结果优化	•提升网络用户忠诚度 •改善社交网络体验 •向目标用户提供有针对性的商品与服务
政府／公用事业	•智能城市信息网络集成 •天气、地理、水电煤等公共数据收集、研究 •公共安全信息集中处理、智能分析	•更好地对外提供公共服务 •舆情分析 •准确预判安全威胁
媒体／娱乐	•收视率统计、热点信息统计、分析	•创造更多联合、交叉销售商机 •准确评估广告效用
零售	•基于用户位置信息的精确促销 •社交网络购买行为分析	•促进客户购买热情 •顺应客户购买行为习惯

大数据商业价值--企业经营决策



某商店卖牛奶，通过数据分析，知道在本店买了牛奶的顾客以后常常会再去另一店买包子，人数还不少，那么这家店就可以考虑与包子店合作，或直接在店里出售包子。

大数据商业价值--个性化营销



银行与客户的交流渠道进行了整合，只要某个客户在网上点击查询了有关房贷利率的信息，系统就会提示呼叫中心在电话交流时推荐房贷产品，如果发现顾客确实对此感兴趣，销售部门就会发送推介信息给客户，如果这位顾客到银行网点办事，业务人员就会详细介绍房贷产品，开始只有少量的线索，但通过多渠道的与顾客交互接触，在这个过程中，令顾客体验了银行精准、体贴的服务，其结果是营业收入大为增加，成本大幅降低。

大数据商业价值--核心是大数据





- 互联网金融并非简单的把传统金融业务搬到网上去，而是充分利用大数据来颠覆银企之间信息不对称的问题。
- 数据是一个平台，因为数据是新产品和新商业模式的基石。
- 推动互联网金融发展的核心正是大数据的价值。

大数据商业价值--大数据公司



大数据改变生活

优化	• 各级政府、主管部门、上市公司、企业集团、外资公司都将基于大数据分析平台优化其决策。
革命	• 大数据分析能力逐渐加强，传统市场研究行业、证券研究所、产业链咨询机构将逐渐消失。
颠覆	• 银行都将基于企业大数据平台开展银行直销业务，同时按照产业链金融服务事业部模式开展业务
改变	• 因大数据系统的出现，所有依赖信息不对称盈利的业务都将消失。

大数据对政府、金融机构、企业来说，象空气一样不可或缺！

摘要

- 大数据背景
- 大数据定义
- 大数据技术
- 大数据应用
- 金融大数据

金融大数据



麦肯锡的研究亦显示，金融业在大数据价值潜力指数中排名第一

金融大数据

- 2017 年7 月，国务院印发的《新一代人工智能发展规划》专门提出了“智能金融”的发展要求，指出要建立金融大数据系统，提升金融多媒体数据处理与理解能力；创新智能金融产品和服务，发展金融新业态；鼓励金融行业应用智能客服、智能监控等技术和装备；建立金融风险智能预警与防控系统。
- 从发展特点和趋势来看，“金融云”快速建设落地奠定了金融大数据的应用基础，金融数据与其他跨领域数据的融合应用不断强化，人工智能正在成为金融大数据应用的新方向，金融行业数据的整合、共享和开放正在成为趋势，给金融行业带来了新的发展机遇和巨大的发展动力。

金融大数据

- 2021年4月，工业和信息化部印发“十四五”大数据产业发展规划
  - 专栏1：数据治理能力提升行动
  - 专栏2：重点标准研制及应用推广行动
  - 专栏3：工业大数据价值提升行动
  - 专栏4：行业大数据开发利用行动
    - 金融大数据。通过大数据精算、统计和模型构建，助力完善现代金融监管体系，补齐监管制度短板，在审慎监管前提下有序推进金融创新。优化风险识别、授信评估等模型，提升基于数据驱动的风险管理能力。
  - 专栏5：企业主体发展能级跃升行动
  - 专栏6：数据安全铸盾行动

金融大数据

- 大数据决策模式对金融更具针对性，发展模式转型、金融创新和管理升级等都需要充分利用大数据技术、践行大数据思维。
- 金融业具备实施大数据的基本条件：
  - 数据众多：所有客户的账户和资金收付交易等结构化数据，以及客服音频、网点视频、网上银行记录、电子商城记录等非结构化数据和大量时间连续、动态变化的数据
  - 处理传统数据积累了大量经验
  - 较高的薪酬能够吸引到实施大数据的人才

金融大数据

- 伴随着大数据应用、技术革新及商业模式创新，金融交易形式日趋电子化和数字化，具体表现为支付电子化、渠道网络化、信用数字化，运营效率得到极大提升。

行业	应用现状
证券期货业	1. 自动化交易；2. 电子券商；3. 数据仓库和决策支持系统；4. 风险监管；5. 证券网络舆情
银行业	1. 客户个性营销；2. 客户关系管理；3. 银行风险管理；4. 电子商务平台和电子银行；5. 小微企业信贷
保险业	1. 保险产品营销；2. 保险欺诈识别；3. 互联网保险
跨行业互联网金融	1. 电子支付；2. 网络信贷与网络基金；3. 网络融资；4. 供应链融资

金融大数据

- 金融数据：一般具有“流数据”特征，需要在短时间内快速处理。具有逻辑关系紧密，处理实时性要求高，可展示性需求强等特征。
  - 数据分析技术：数据挖掘，机器学习等AI技术
  - 数据管理技术：关系型和非关系型数据管理、数据融合和集成技术、ETL等技术
  - 数据处理技术：分布式计算，内存计算，流处理技术等
  - 数据展示技术：可视化技术、历史流展示技术、空间信息流展示技术等。

金融大数据





- 量化交易，程序化交易，高频交易是大数据应用比较多的领域。
- 全球2/3的股票交易量是由高频交易所创造的，参与者总收益每年高达80亿美元。
- 其中，大数据算法被用来作出交易决定。现在，大多数股权交易都是通过大数据算法进行，这些算法越来越多地开始考虑社交媒体网络和新闻网站的信息来在几秒内做出买入和卖出的决定。
- 当一个产品可以在多个交易所交易时，会形成不同的定价，在这当中，谁能够最快地捕捉到同一个产品在不同交易所之间的显著价差，谁就能捕捉到瞬间套利机会，技术成为了重要因素。

金融大数据

- 大数据为金融业带来的机遇
  - 更广阔的业务发展空间
  - 更精准的决策判断能力
  - 更优秀的经营管理能力
- 大数据给传统金融业带来的挑战
  - 数据资产管理水平仍待提高
  - 应用技术和业务探索仍需突破
  - 行业标准和安全规范仍待完善
  - 顶层设计和扶持政策还需强化

THANK YOU



南京大學
NANJING UNIVERSITY

南京大学计算机软件研究所
Institute of Computer Software, Nanjing University