Cloud Computing



摘要

- 发展背景
- 技术特点
- 实现机制
- 云原生
- 数据湖



云计算发展的背景

- 从计算模式的演变看计算技术发展的趋势
  - 计算技术发展的历史就是不同层面上计算模式发展和演变的历史；而相关支撑技术的成熟为计算模式的演变和实现提供了基础和条件
  - 计算模式的演进过程是受到一定的发展规律支配的，存在一定的必然性



云计算发展的背景

- 从计算模式的演变看计算技术发展的趋势
  - 计算模式变革的两大根本目标：
    - 更方便快捷的使用方式
    - 更强大的计算能力

在提供更强大计算能力的同时，提供更加方便快捷的使用方式，是贯穿整个计算技术发展的主线

云计算发展的背景

- 从计算模式的演变看计算技术发展的趋势

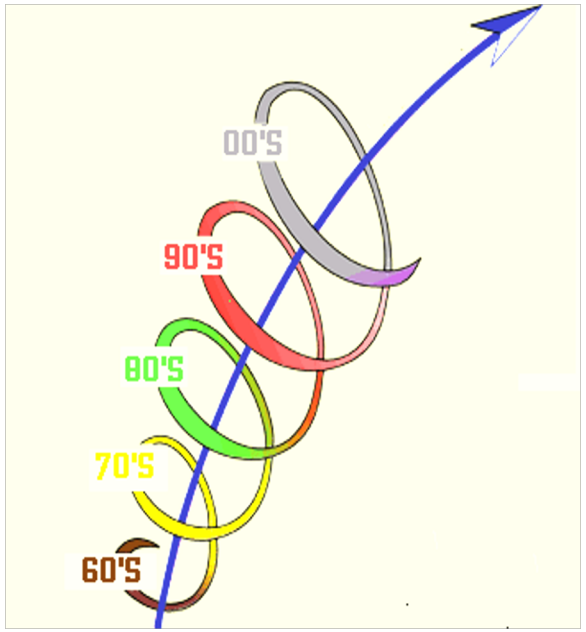
“天下大势，合久必分，分久必合”

“否定之否定，螺旋式上升”

95-06： 互联网/网格/集群/数据中心 → 集中

80-90’s: 个人计算机人手一台 → 分散

60-70’s: 大型机/集中式/分时共享 → 集中



云计算发展的背景

- 从计算模式的演变看计算技术发展的趋势
  - 60-70's: 大型机(mainframe)、集中式、分时共享

IBM创始人托马斯·沃森 (Thomas J. Watson):

"我认为全球大概只需要五台计算机就够了。"



云计算发展的背景

- 从计算模式的演变看计算技术发展的趋势
  - 80-90's：个人计算机(PC)人手一台



因此，比尔盖茨产生了一个伟大的梦想：

“让每一张桌子上有一台电脑！”

这个梦想成就了微软，推动了个人计算时代的来临。

比尔盖茨，1981年表示：“640KB内存应该对任何人都够用了。”

1980年微软开发DOS时曾认为：“DOS只能管理1MB的空间，因为我们无法想象还有什么应用软件会需要更多的内存。”

云计算发展的背景

- 从计算模式的演变看计算技术发展的趋势
  - 95-06：互联网/网格/集群/数据中心
    - 分离的PC需要互连以交换信息共享资源→ 互联网
    - 连接更多的计算资源以解决大的计算问题→ 网格计算
    - 用很多微处理器构建具有大型机处理能力的系统→ 集群
    - 很多的集群存储处理大量的信息→ 数据中心

Yahoo，Amazon， Google……

云计算发展的背景

- 从计算模式的演变看计算技术发展的趋势
  - 2006年至今 “更分散同时也更集中”
    - 前端更加分散：2006年后，一方面前端更加分散，以智能手机和iPad为代表的智能移动终端，推动移动计算技术发展

      “PC太大了，每个人口袋里应该放一台！”

      传感网络、普适计算、物联网概念和技术

      “每一粒沙子都应该是一台计算机！”

移动计算和物联网



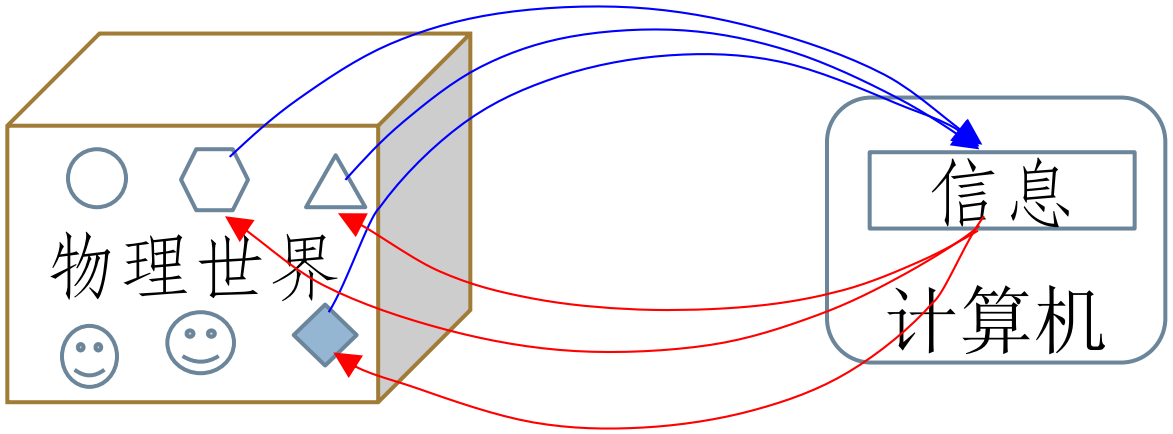
云计算发展的背景

- 从计算模式的演变看计算技术发展的趋势
  - 2006年至今 “更分散同时也更集中”
    - 后端更加集中：另一方面，后端更加集中，出现云计算概念和技术，让计算成为像水电一样的公共服务，便于资源共享，以及提供超大的计算能力

云计算

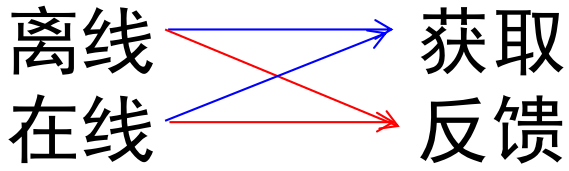
云计算发展的背景

- 从计算模式的演变看计算技术发展的趋势
  - 从信息处理及其模式看物联网的发展
    - 信息是物理世界中对象和事物状态属性的抽象和表示
    - 信息处理是借助于计算机对信息进行加工处理的过程
    - 信息处理完成后将反作用于物理世界中的对象和事物



云计算发展的背景

- 从计算模式的演变看计算技术发展的趋势
  - 从信息处理及其模式看物联网的发展
    - 按照从物理对象获取和反馈信息的方式和对象与计算系统之间的耦合度，信息处理可分为4种模式：



    - 早期计算模式主要是离线获取、离线反馈的松耦合模式，信息处理和使用的效率不高

云计算发展的背景

- 从计算模式的演变看计算技术发展的趋势
  - 从信息处理及其模式看物联网的发展
    - 而现在越来越强调对物理对象信息处理的普遍性、时效性和方便性，因此越来越需要在线获取和在线反馈的紧耦合模式，这就产生“物联网”的概念和计算模式
    - 人作为物理世界中一类特殊对象、以及控制和使用计算系统的主体，如果我们综合考虑人、计算系统和物理世界对象三者间的交互作用，这就产生“人机物系统”的概念和计算模式

云计算发展的背景

- 从计算模式的演变看计算技术发展的趋势
  - 云计算与互联网
    - 物联网是前端计算能力向物理世界的前伸，使得计算系统与物理世界对象深度融合，获取信息更加快速和多样，信息量迅猛增长
    - 云计算则是计算系统后端处理能力的拓展，为快速有效处理大量物理世界的信息提供有效的计算手段和计算能力
    - 两者将相互结合，推动新的计算模式和计算技术发展



什么是云计算?

- Cloud Computing, Utility Computing, Service Computing……
- 通过集中式远程计算资源池，以按需分配方式，为终端用户提供强大而廉价的计算服务能力
  - 工业化部署、商业化运作的大规模计算能力
  - 一种新的、可商业化的计算和服务模式
  - 计算能力像水电煤气一样，按需分配使用
  - 资源池物理上对用户透明就像在云端一样

云计算概念的由来

“云计算”的概念在2006年由Google公司正式提出
但最初的思想雏形可追溯到更早的时间



“The computation and the data and so forth are in the servers. … We call it cloud computing.”
(Erick Schmidt, 2006)



“computation may someday be organized as a public utility”
(John McCarthy, 1960)

云计算的发展目标

- 云计算的一个重要目标是，把计算能力变成像水电等公用服务一样，随用随取，按需使用。故此也有人把云计算称为“Utility Computing”。
- 这里Utility不是效用、实用的意思，在英文里Utility有一个专门的含义，专指类似于水电煤气的公用服务，故Utility Computing应译为“公用服务计算”。

云计算的主要特点



引自：刘鹏《云计算》

云计算的分类

按云计算服务层面进行分类



针对性更强，它将某些特定应用软件功能封装成服务

如：Salesforce online CRM

对资源的抽象层次更进一步，提供用户应用程序运行环境

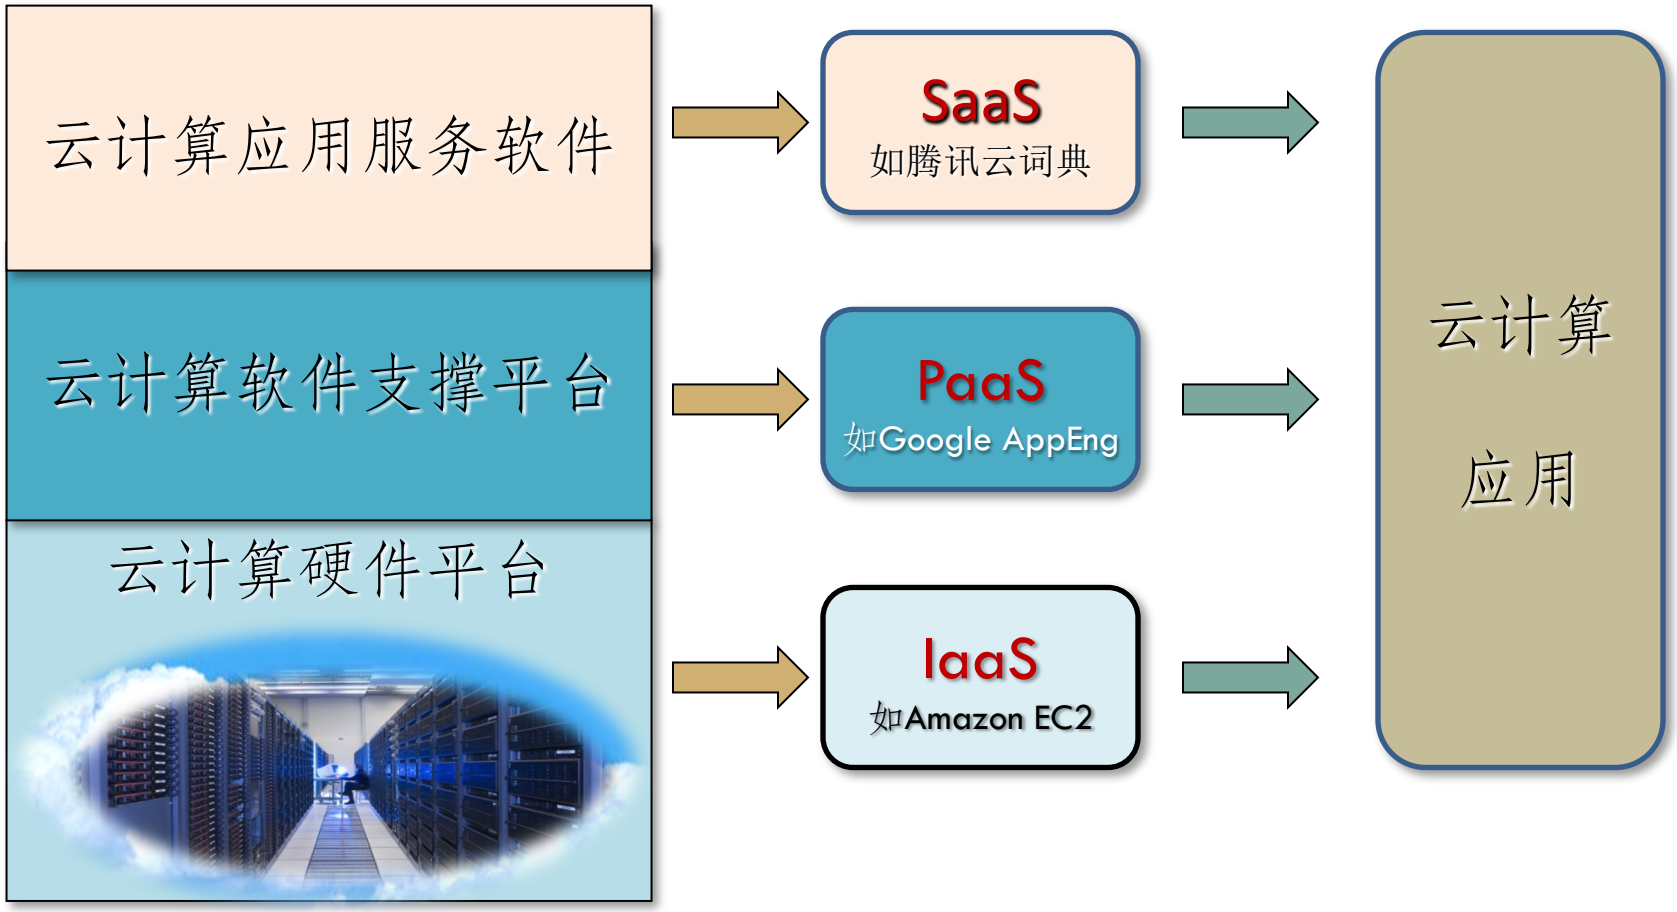
如：Google App Engine
Microsoft Windows Azure

将硬件设备等基础资源封装成服务供用户使用

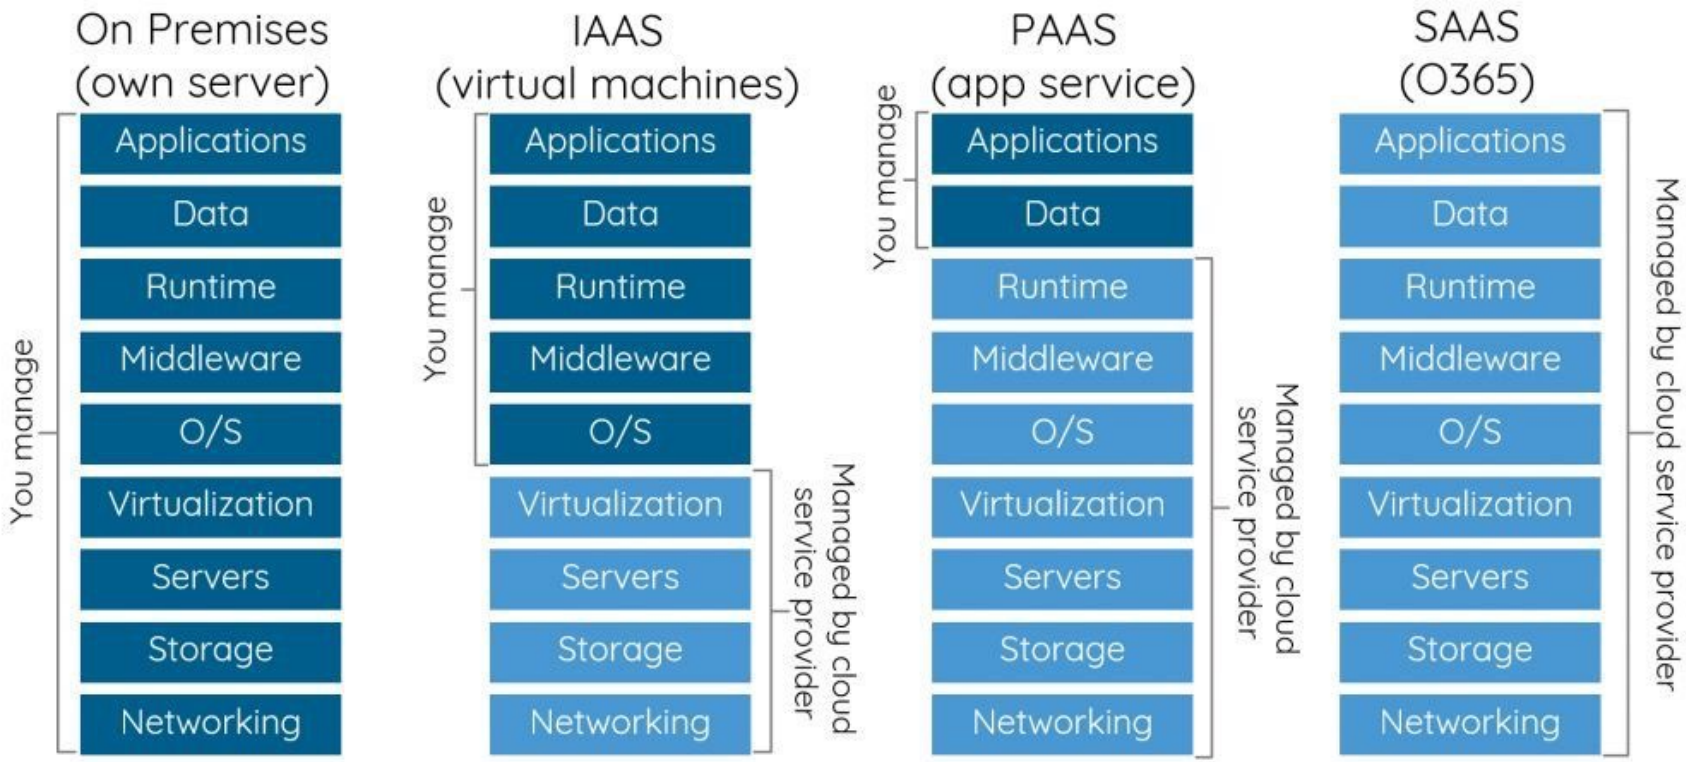
如：Amazon EC2/S3

云计算的分类

- 按云计算服务层面进行分类



云计算的分类


On Premises
(own server)
Applications
Data
Runtime
Middleware
O/S
Virtualization
Servers
Storage
Networking
You manage
IAAS
(virtual machines)
Applications
Data
Runtime
Middleware
O/S
Virtualization
Servers
Storage
Networking
You manage
Managed by cloud service provider
PAAS
(app service)
Applications
Data
Runtime
Middleware
O/S
Virtualization
Servers
Storage
Networking
You manage
Managed by cloud service provider
SAAS
(O365)
Applications
Data
Runtime
Middleware
O/S
Virtualization
Servers
Storage
Networking
Managed by cloud service provider

云计算的分类

按云计算系统类型进行分类

美国联邦云计算战略报告中，定义了4种云：

- 公用云：提供面向社会大众、公共群体的云计算服务。如Amazon云平台，Google App Engine。公有云有很多优点，但最大的一个缺点是难以保证数据的私密性
- 私有云：提供面向应用行业/组织内的云计算服务。如政府机关、移动通信、学校等内部使用的云平台。私有云可较好地解决数据私密性问题，对移动通信、公安等数据私密性要求特别高的企业或机构，建设私有云将是一个必然的选择
- 社区云：提供面向社团组织内用户使用的云计算平台。如美国航天局(NASA) Nebula云平台为NASA内的研究人员提供快速的IT访问服务
- 混合云：包含以上2种以上云计算类型的混合式云平台

云计算发展的推动力

- 应用需求推动力
  - 大粒度应用系统日益增多，系统规模日益扩大
    - 应用系统数据量爆炸性增长
    - 超大的计算量和计算复杂度
  - 小粒度应用系统资源重复、无法共享



云计算发展的推动力

- 技术发展推动力
  - 云计算是诸多计算技术发展成熟与自然进化的产物
    - 计算机虚拟化技术、大规模并行计算、分布式存储、面向服务构架、公用服务计算等诸多技术广泛应用
    - 计算机系统规模和处理能力迅速扩大
    - 技术发展成熟与自然进化的结果

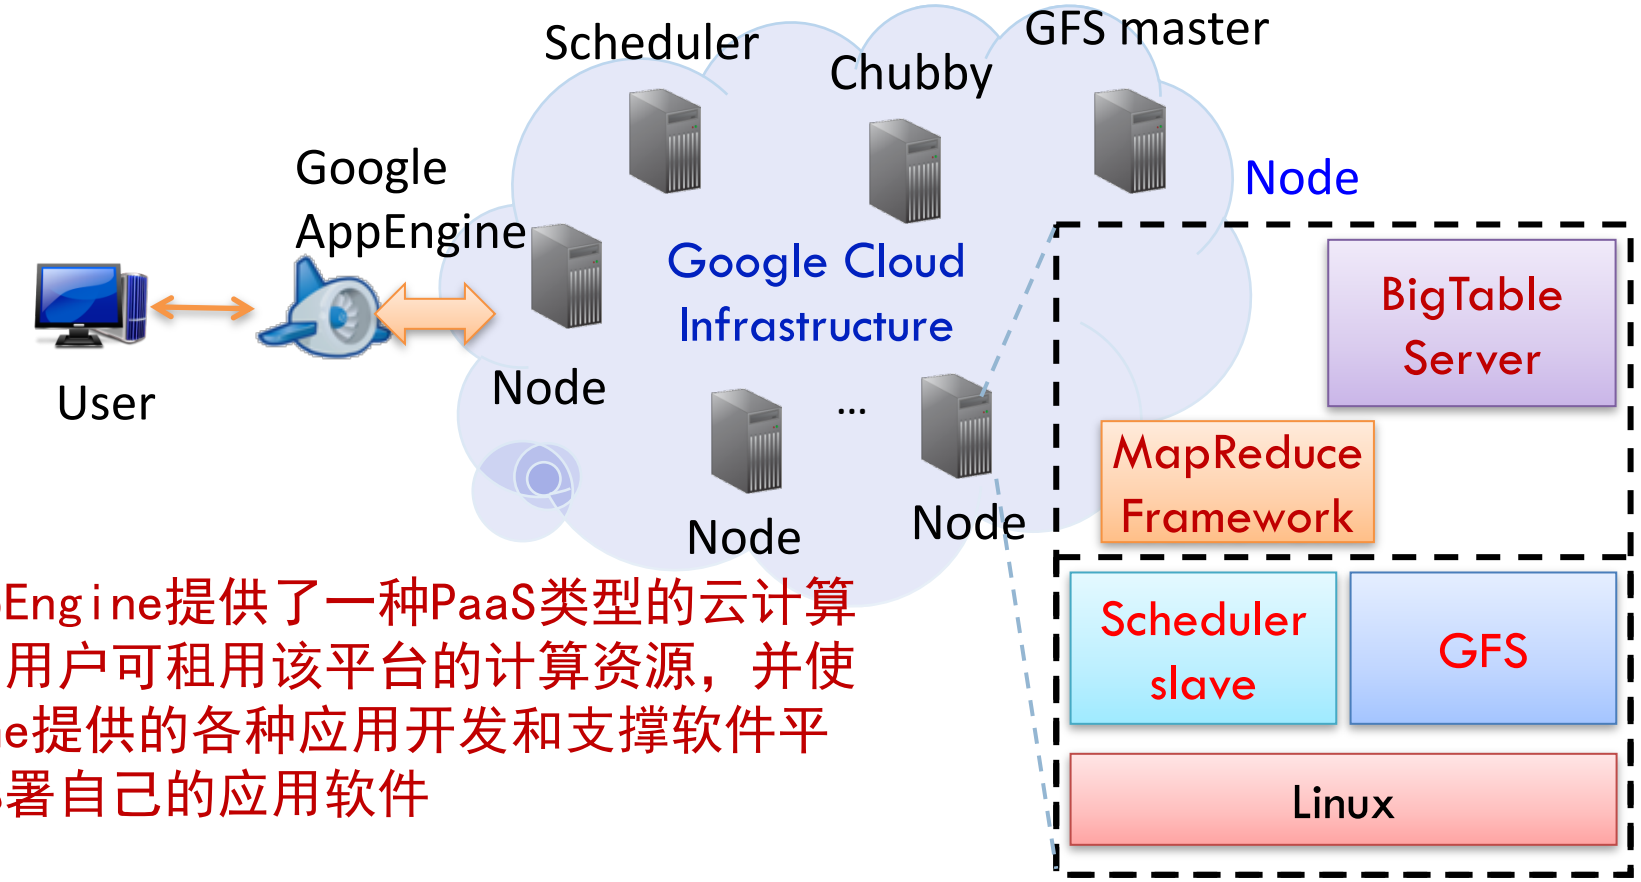


云计算发展现状与趋势

- 业界云计算技术的发展
  - 自2006年Google公司提出云计算技术的概念后，全球IT著名企业纷纷予以极大关注，并投入了巨大力量进行云计算技术的研究开发。
  - MapReduce 的论文实际上解决了云计算发展的所有问题，在某种意义上开启了云计算的大门。

Google Cloud Infrastructure

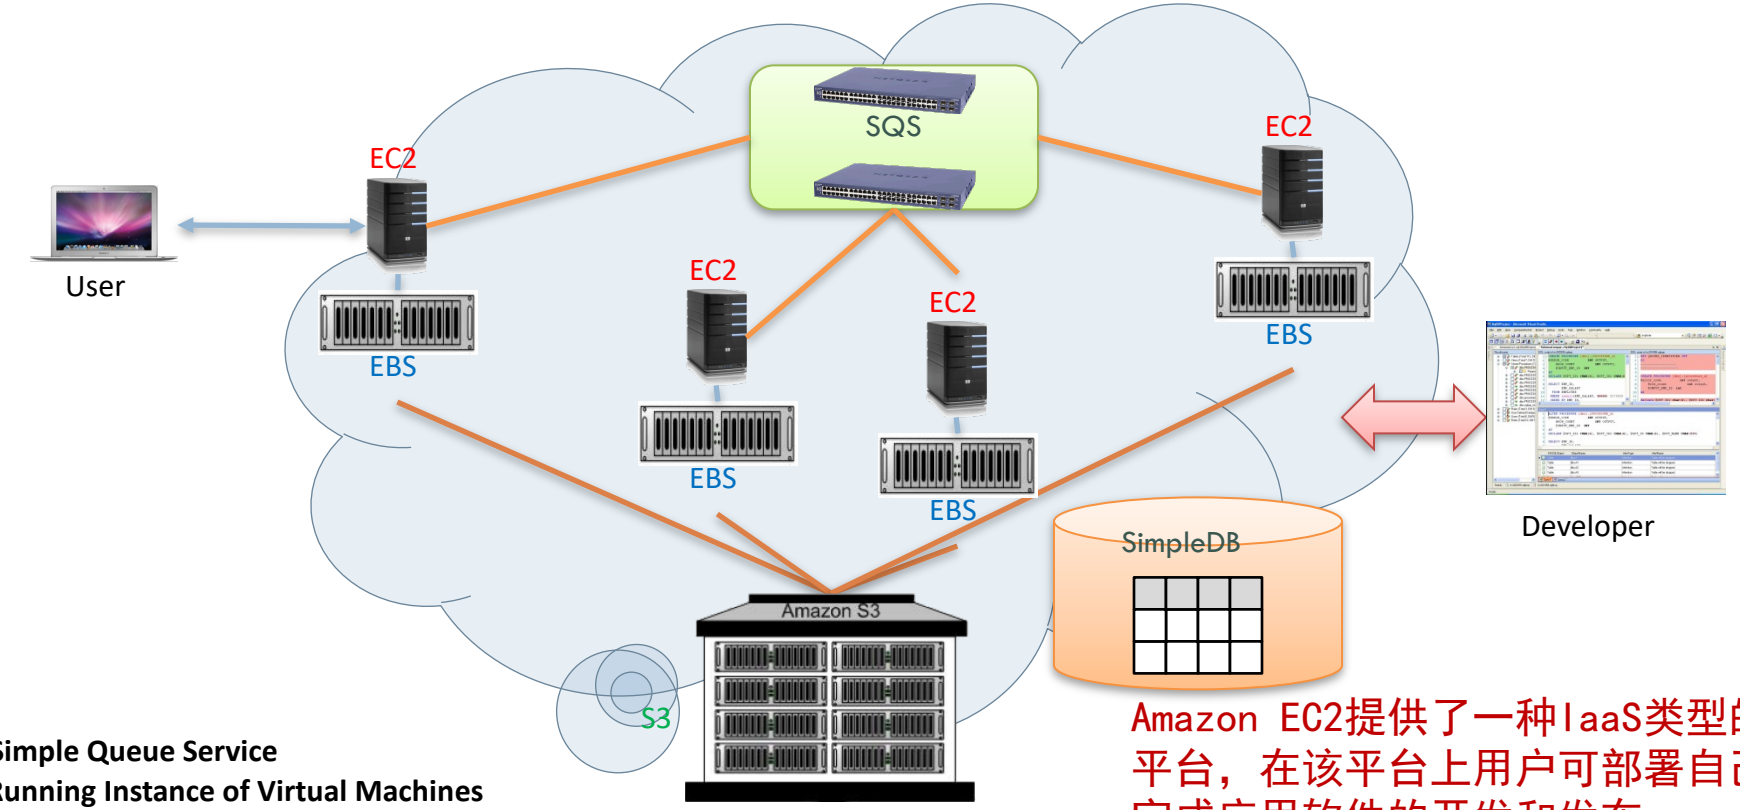
- Google AppEngine，PaaS型公用云平台



Google AppEngine提供了一种PaaS类型的云计算服务平台，用户可租用该平台的计算资源，并使用AppEngine提供的各种应用开发和支撑软件平台开发和部署自己的应用软件

Amazon Elastic Computing Cloud

- Amazon EC2，IaaS型公用云平台



SQS: Simple Queue Service
EC2: Running Instance of Virtual Machines
EBS: Elastic Block Service, Providing the Block Interface, Storing Virtual Machine Images
S3: Simple Storage Service, SOAP, Object Interface
SimpleDB: Simplified Database

Amazon EC2提供了一种IaaS类型的云计算服务平台，在该平台上用户可部署自己的系统软件，完成应用软件的开发和发布。

Microsoft Cloud Services

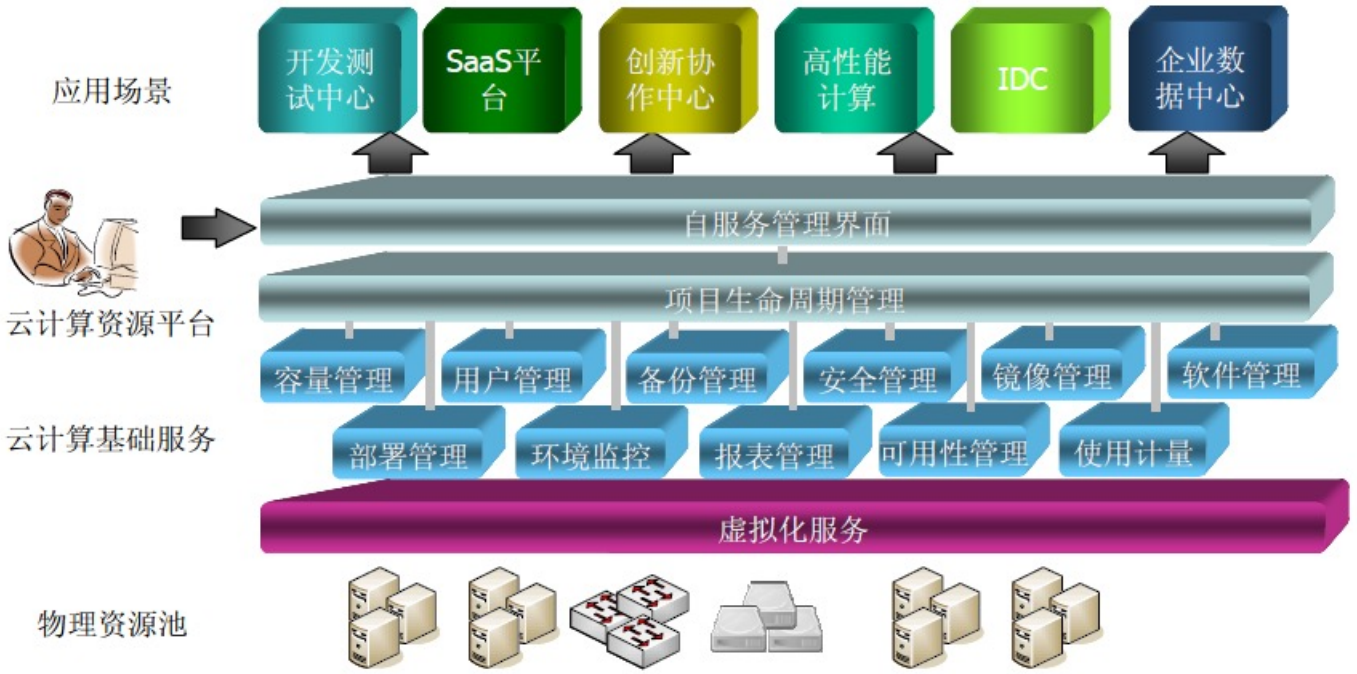
- Windows Azure，私有云平台管理和服务软件



IBM云计算方案

- 私有云计算平台管理和服务软件

提供私有云计算资源管理软件平台，主要负责管理和调度虚拟计算资源，完成资源申请、调度和管理等整个生命周期管理



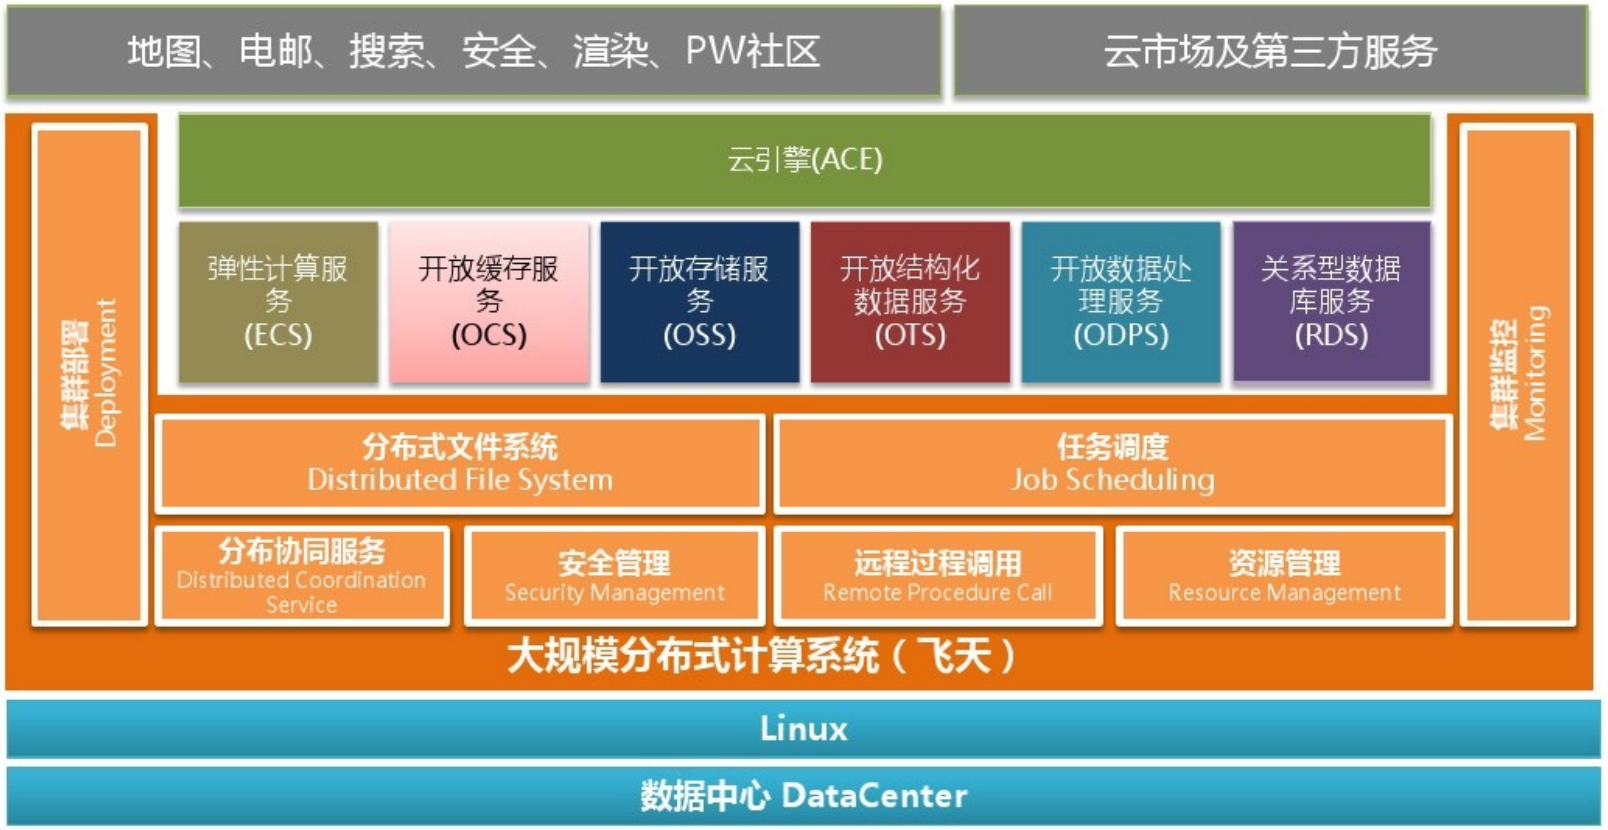


云计算发展现状与趋势

- 其它国内外IT企业云计算研发
  - 除以上几家全球著名的IT企业外，其它著名IT企业如Cisco、HP、EMC、VMWare等，都在大力推进云计算技术和系统研发。
  - 国内各大著名IT企业，如中国移动、中国电信、中国联通、阿里巴巴、腾讯、百度、万网等，都在大力推动云计算技术和系统研发。
  - 尤其是著名的网络设备制造商中兴通信和华为，正在开始从传统的网络电信设备制造向计算技术领域转移，他们把云计算作为实现重大战略转移的一个重大契机。

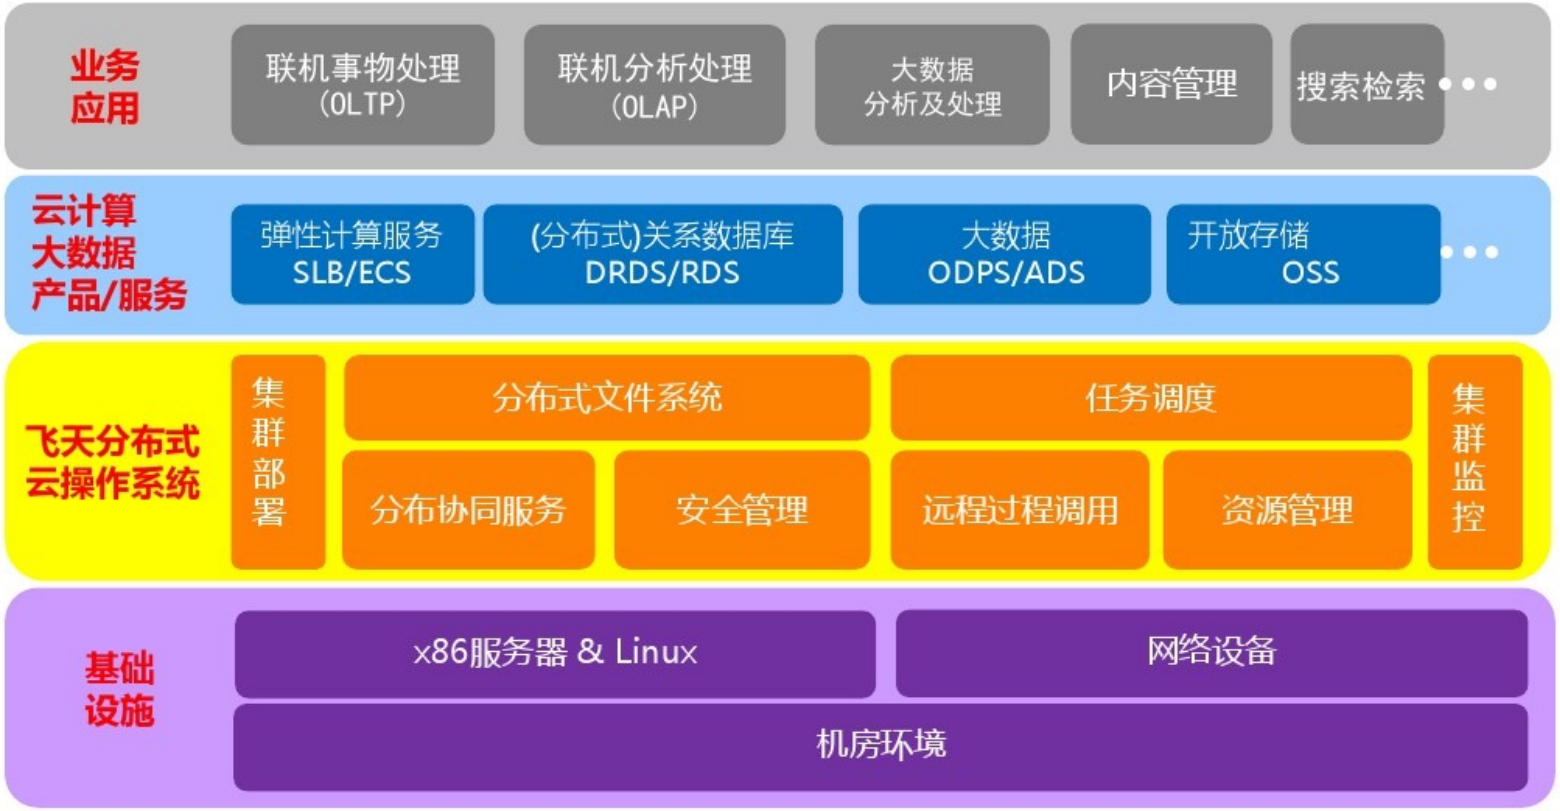
阿里云

阿里云体系架构-1级架构图



阿里云

阿里云的技术层次（云计算 & 大数据）



华为云

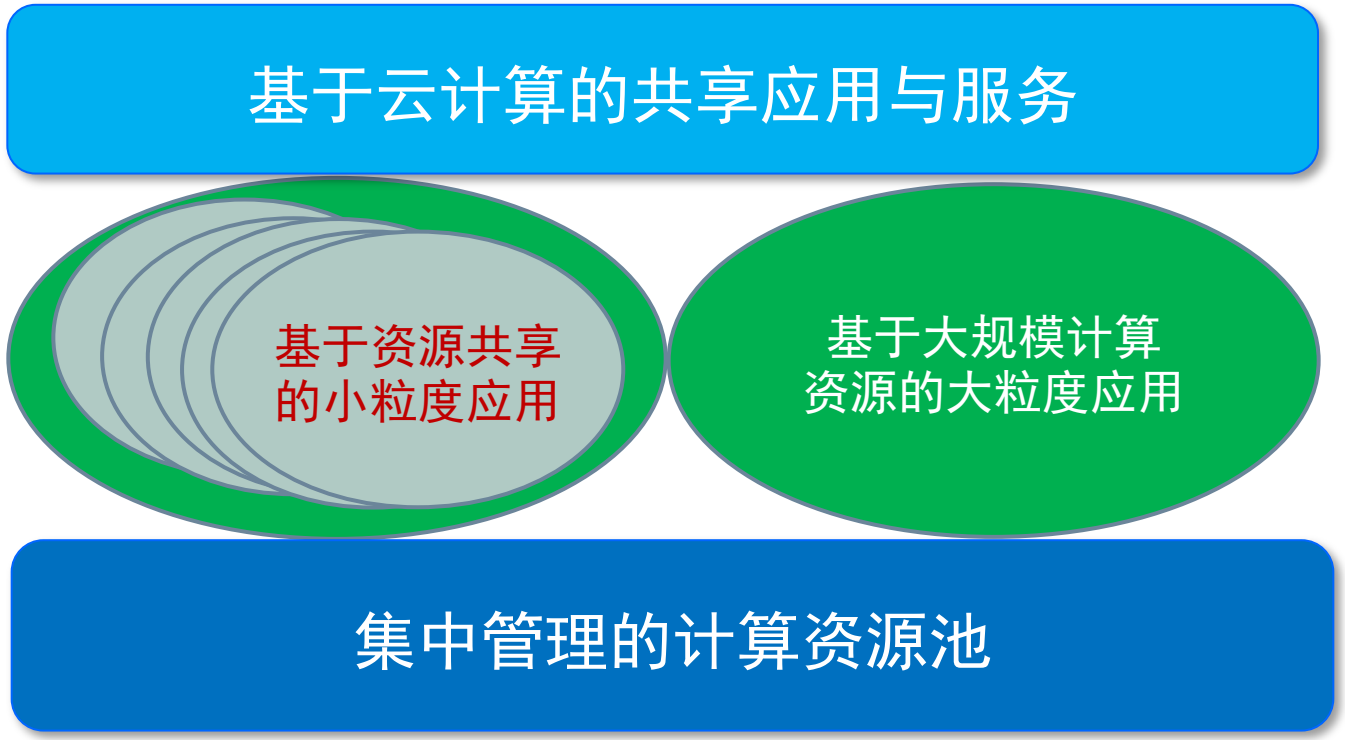

商业咨询
架构设计
Turnkey
维护咨询
评估优化
专业服务
桌面云
企业云
IDC云
支撑云
行业云
自动化管理和调度(Galax8800)
搜索引擎
大规模并行计算
分布式缓存
DHT存储引擎
分布式文件系统
虚拟化(UVP)
云计算硬件资源
计算
存储
网络
安全
基础设施配套
供电
制冷
布线
消防
闭路
安全
集装箱
运维中心
安全管理
平台管理
网络管理
设施管理
专业管理

云计算发展现状与趋势

- 云计算提供一种新的计算模式和服务模式。云计算是计算技术的一次重大变革，作为今后计算发展的潮流将大大改变现有的计算模式，对计算技术领域本身以及各个应用行业都将带来重大的影响，提供更多的发展机遇。
- 通过云计算人们能获得前所未有的强大计算能力，并能按需分配，按需付费，提升了本地计算能力但使用成本低廉，而且还能大幅削减不断升级软硬件系统的费用。
- 通过云计算平台强大的计算和存储能力，人们能完成传统系统所无法完成的计算和处理，开发出更强大的应用功能，提供更多智能化应用。

云计算解决什么主要问题?

- 1）为小粒度应用提供一个集中管理的巨大的计算资源池，提供巨大的计算资源和能力资源共享；2）为大粒度应用提供大规模计算能力



云计算的关键技术





云计算的关键技术

- 虚拟化技术：虚拟机的安装、设置、调度分配、使用、故障检测与失效恢复等，包括服务器虚拟化、存储虚拟化、网络虚拟化和桌面虚拟化等。
- 云计算构架技术：研究解决适合于云计算的系统软硬件构架
- 资源调度技术：解决物理或虚拟计算资源的自动化分配、调度、配置、使用、负载均衡、回收等资源管理
- 并行计算技术：针对大数据或复杂计算应用，解决数据或计算任务切分和并行计算算法设计问题

云计算的关键技术

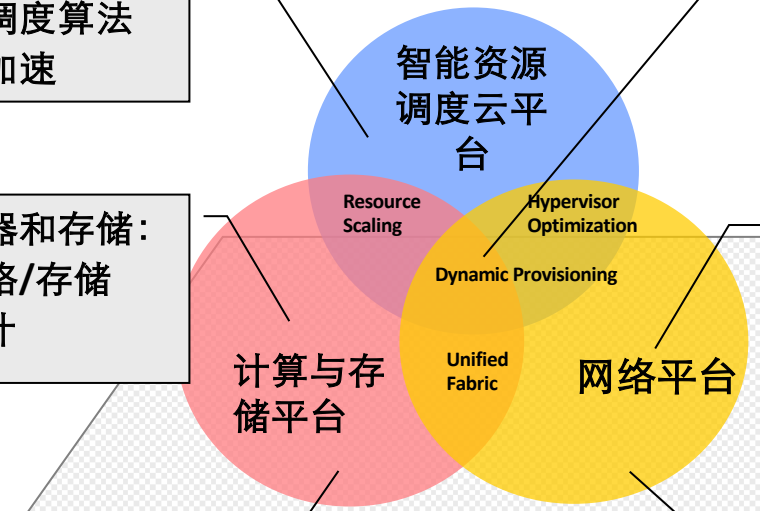
- 大数据存储技术：解决大数据的分布存储、共享访问、数据备份等问题
- 云安全技术：解决云计算系统的访问安全性、数据安全性（包括数据私密性）等问题
- 云计算应用：面向各个行业的、不同形式的云计算应用技术和系统
- 此外，还有云计算中心的节能和散热等工程技术问题

云计算技术架构

- 虚拟化软件：高性能、高可靠性、智能调度算法
- 虚拟化的硬件加速

- 定制化的服务器和存储：大内存、高网络/存储IOPS、简化设计

- 数据中心安全性：可信赖、完整性、可用性



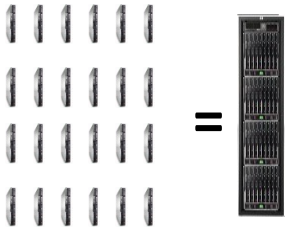
- 云计算一体化自动管控
- 分布式计算/存储框架

- 规模虚拟互联与多租户
- 网络虚拟化
- 智能网络感知和调度

- E2E集成交付能力
- 绿色节能工程设计能力：智能化功耗管理、散热（液冷、精确制冷）、模块化交付

智能资源调度云平台、虚拟网络、分布式计算/存储是云计算的最基本组件

云计算技术体系

计算架构	云计算硬件	云计算软件
模式： Scale Out 	服务器：低可靠性，高性能IO	并行计算技术
		分布式数据库管理
		分布式文件管理
整体性能最优	大容量虚拟化网络	网格管理与虚拟化技术
非冗余设计，基于软件可靠性		Web框架
增加节点实现可扩展性	存储: 低成本、分布式、多备份	智能化云计算系统管理技术

云计算每个单点技术不仅是老技术的罗列，而是各个技术全新的变革，同时整合各种新技术给云计算中心带来全新的价值

云计算架构的技术趋势

规模化

只有具有一定规模，才能提供**规模效益**。数据大集中、Web2.0业务、物联网等**信息爆炸**也为云计算提供服务平台。



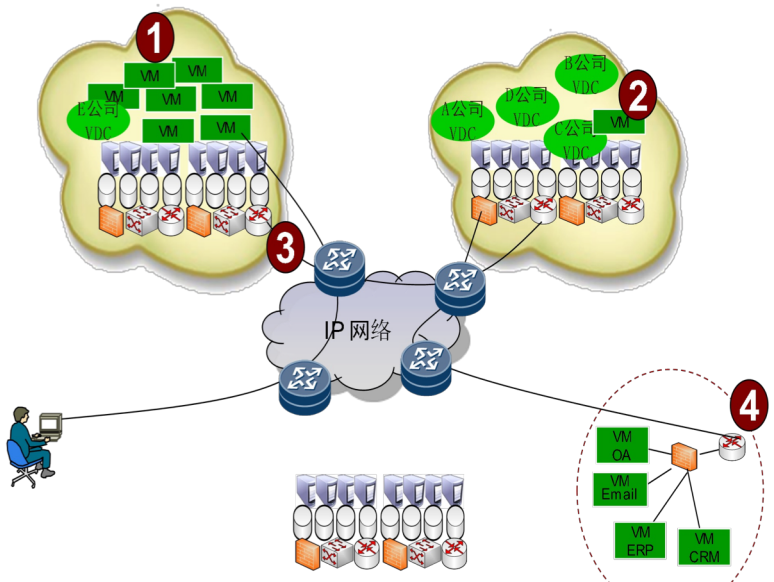
虚拟化

虚拟化分为**大聚小和小聚大**两种模式，云计算中心的数据流量变得**不确定且异常复杂。**

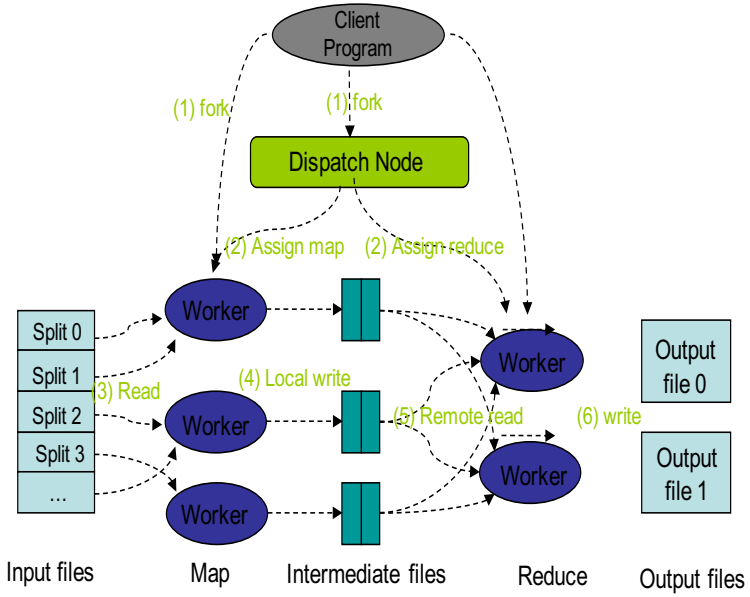
智能化

云计算最重要的就是业务快速**自动部署**，同时将计算资源与网络资源的**智能融合**

云计算：规模化带来的变革



云计算多级负载均衡



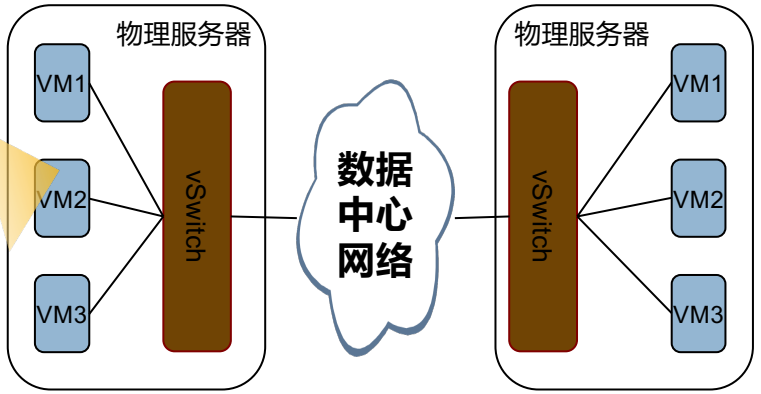
复杂云业务调度流程

云计算中心的规模化建设需要多级负载均衡，复杂云业务调度流程使得云计算中心的容量、互联和适应性上带来全面的挑战。

云计算：虚拟化带来的巨变



云计算数据中心

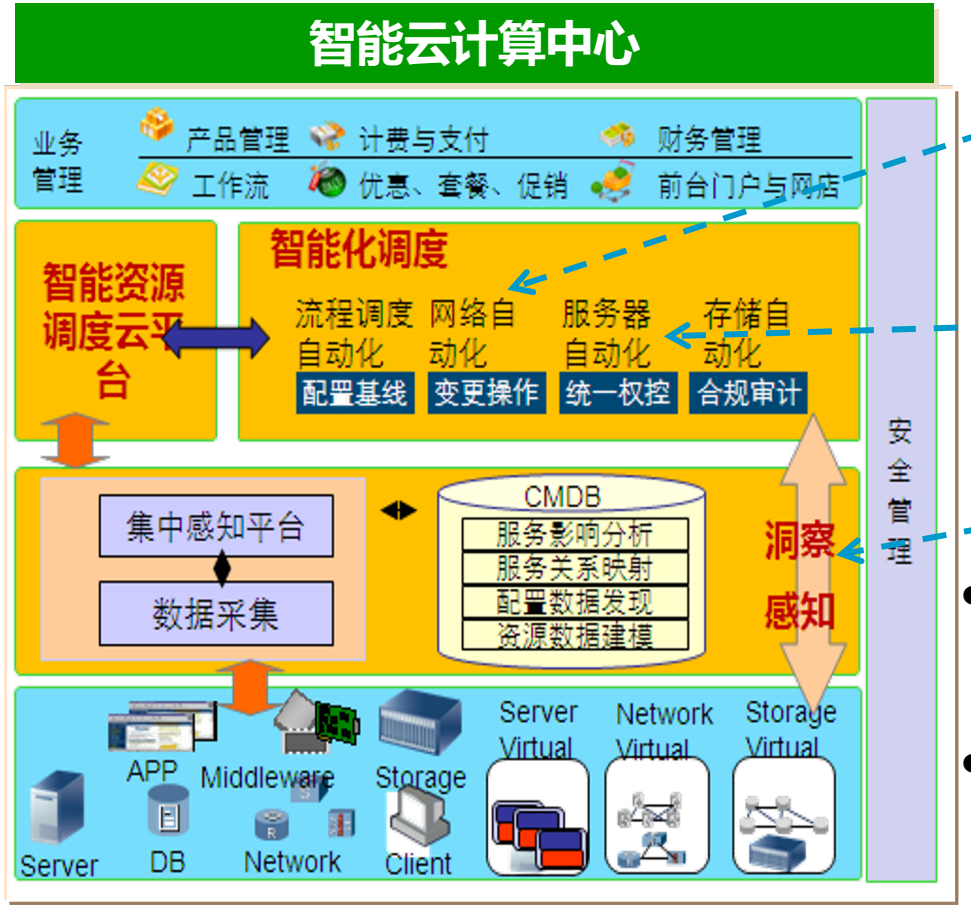


虚拟机互联

- 随着虚拟机应用的不断深入，该种模式需要对虚拟机进行感知，同时完成虚拟机之间的互联。
- 典型的应用：亚马逊基于Xen 提供IaaS架构的虚拟专用云（VPC），在其受欢迎的弹性计算云私人部分（EC2）服务设施，从而使客户通过一个达到VPN连接。 如：BT、Telefornica等

云计算虚拟化给云计算中心带来巨变，而虚拟机具有规模虚拟机互联、规模虚拟机迁移以及多租户等多重属性，给云计算中心带来了全面的挑战。

云计算：智能化带来资源融合





- 通过云业务自动部署，自动对计算、网络和存储资源进行部署，为客户提供更便捷的云服务
- 通过对计算和网络资源实时监控，根据网络状况情况动态调整云计算的策略，进一步实现了云计算资源智能

云计算智能化全面对网络和计算等资源进行状态感知，使得云计算中心各种资源合理有效利用，实现云业务的自动部署和智能化调度，构建智能云计算中心。

云计算的关键技术

怎样才算是云计算系统?

一个计算系统必须具备以下两个特征才能算是云计算系统（至少具备第一个特征）：

- 资源虚拟化和弹性调度解决小粒度应用资源共享

  基于虚拟化和弹性调度，以按需分配方式，为小粒度应用提供计算资源，实现资源共享

- 大数据存储处理和并行计算服务提供大粒度应用计算能力

  基于云端的强大而廉价的计算能力，为大粒度应用提供传统计算系统或用户终端所无法完成的计算服务。这些计算能力包括海量数据存储能力、以及大规模并行计算能力。



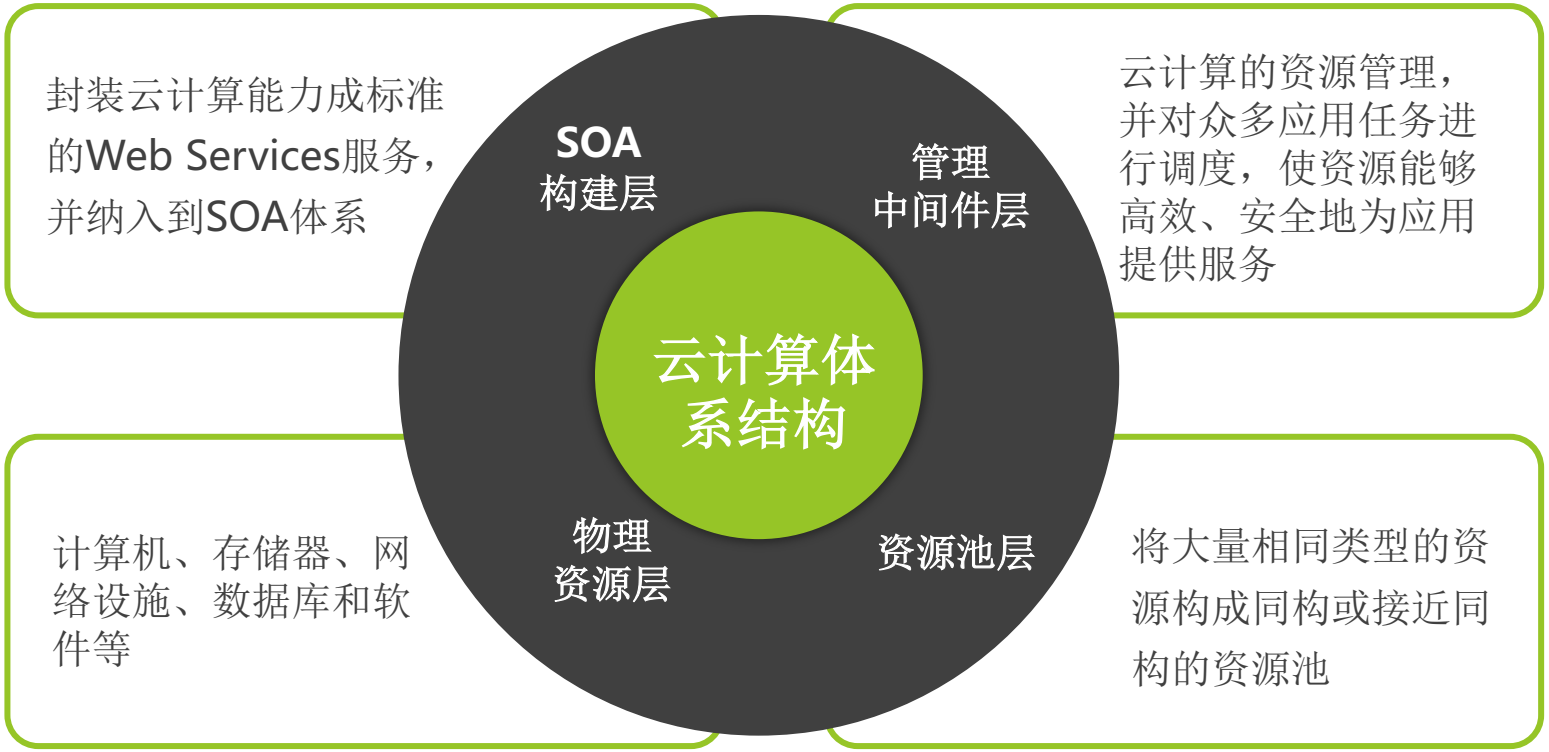
云计算的关键技术

- 云计算长定义
  - 云计算是一种商业计算模型。它将计算任务分布在大量计算机构成的资源池上，使各种应用系统能够根据需要获取计算力、存储空间和信息服务。
- 云计算短定义
  - 云计算是通过网络按需提供可动态伸缩的廉价计算服务。

云计算的实现机制


SOA构建层
服务接口
服务注册
服务查找
服务访问
服务工作流
管理中间件层
用户管理
账号管理
用户环境配置
用户交互管理
使用计费
任务管理
映像部署和管理
任务调度
任务执行
生命期管理
资源管理
负载均衡
故障检测
故障恢复
监视统计
安全管理
身份认证
访问授权
综合防护
安全审计
资源池层
计算资源池
存储资源池
网络资源池
数据资源池
软件资源池
物理资源层
计算机
存储器
网络设施
数据库
软件

云计算的实现机制



管理中间件层和资源池层是云计算技术的最关键部分，SOA构建层的功能更多依靠外部设施提供。

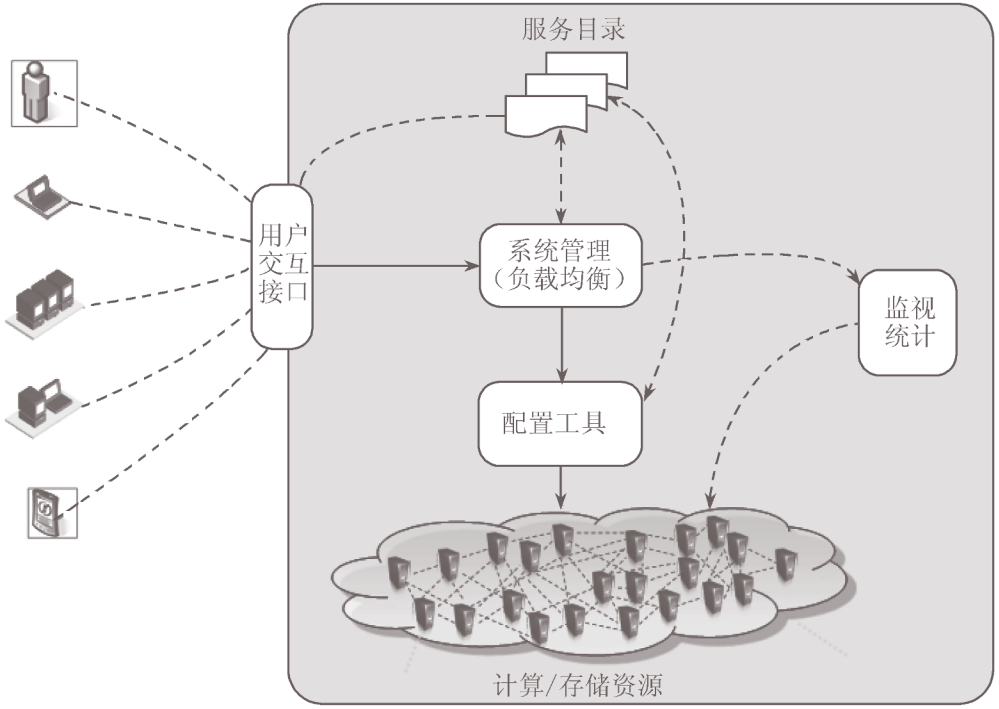
云计算的实现机制

云计算的管理中间件层



云计算的实现机制

简化的IaaS实现机制图



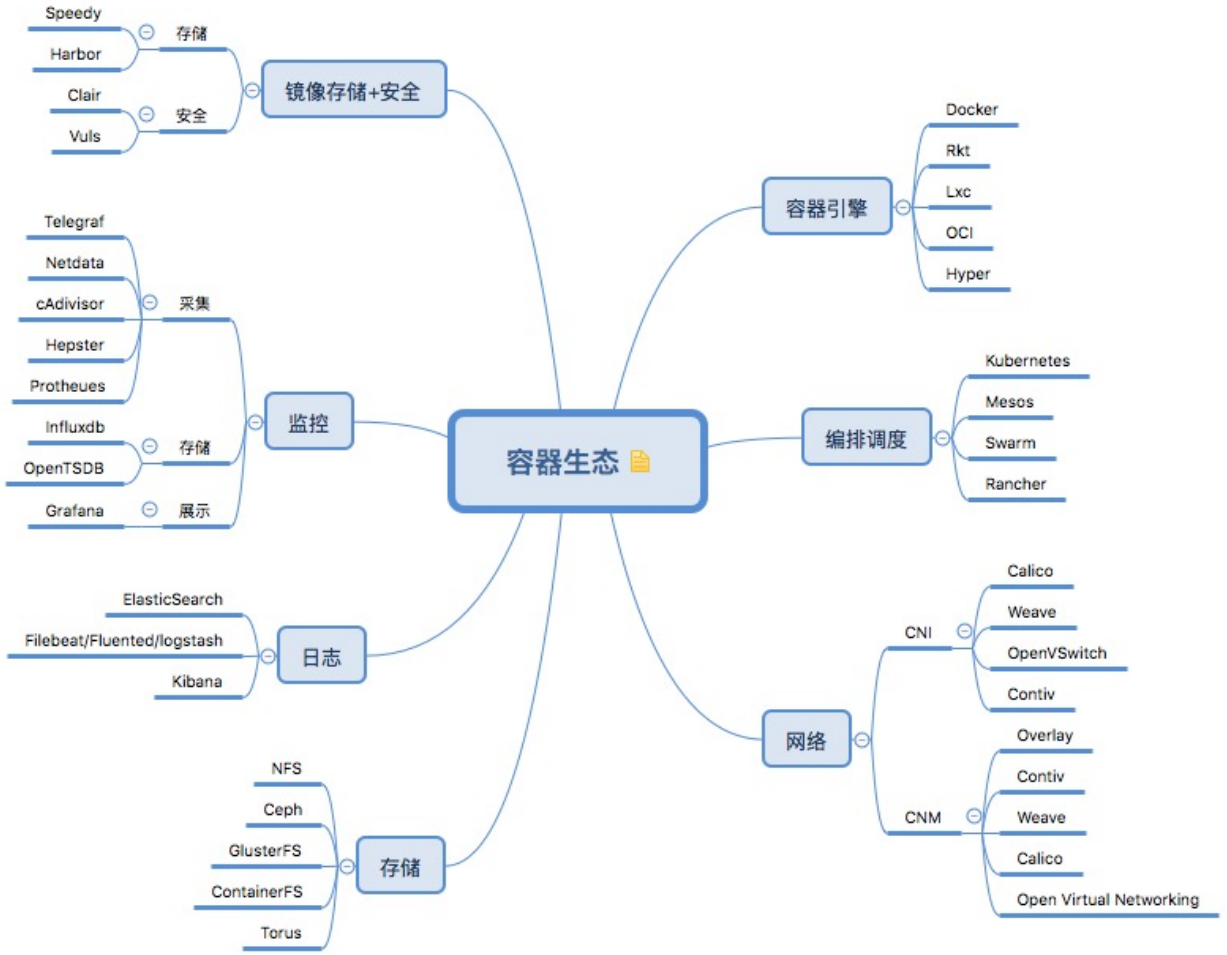
- 用户交互接口向应用以Web Services方式提供访问接口，获取用户需求。
- 服务目录是用户可以访问的服务清单。
- 系统管理模块负责管理和分配所有可用的资源，其核心是负载均衡。
- 配置工具负责在分配的节点上准备任务运行环境。
- 监视统计模块负责监视节点的运行状态，并完成用户使用节点情况的统计。



容器云

- 容器云以容器为资源分割和调度的基本单位，封装整个软件运行时环境，为开发者和系统管理员提供用于构建，发布和运行分布式应用的平台。
- 当容器云专注于资源共享与隔离、容器编排与部署，它更接近传统的IaaS；当容器云渗透到应用支撑与运行时环境时，它更接近于传统的PaaS。

容器技术生态



https://blog.csdn.net/zxy_666



容器技术的优点

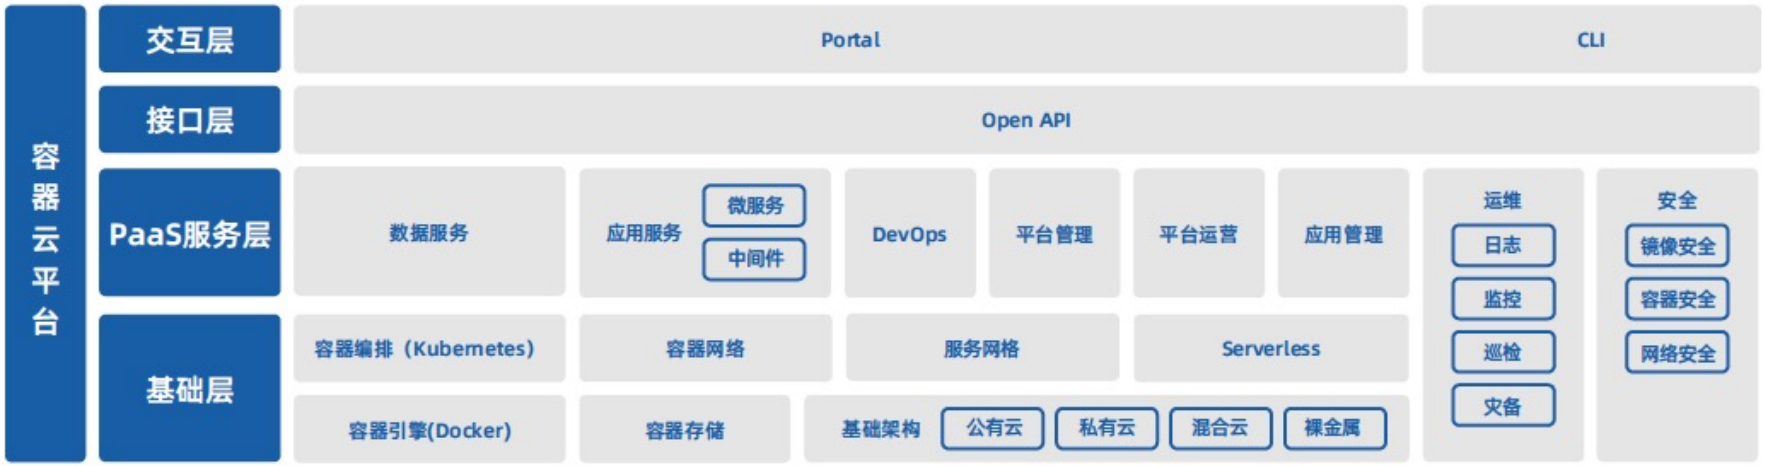
- 敏捷应用程序的创建和部署：与使用 VM 镜像相比，提高了容器镜像创建的简便性和效率。
- 持续开发、集成和部署：通过快速简单的回滚（由于镜像不可变性），支持可靠且频繁的 容器镜像构建和部署。
- 关注开发与运维的分离：在构建/发布时而不是在部署时创建应用程序容器镜像，从而将应用程序与基础架构分离。
- 可观察性不仅可以显示操作系统级别的信息和指标，还可以显示应用程序的运行状况和其他指标信号。
- 跨开发、测试和生产的环境一致性：在便携式计算机上与在云中相同地运行。



容器技术的优点

- 跨云和操作系统发行版本的可移植性：可在 Ubuntu、RHEL、CoreOS、本地、Google Kubernetes Engine 和其他任何地方运行。
- 以应用程序为中心的管理：提高抽象级别，从在虚拟硬件上运行 OS 到使用逻辑资源在 OS 上运行应用程序。
- 松散耦合、分布式、弹性、解放的微服务：应用程序被分解成较小的独立部分，并且可以动态部署和管理 - 而不是在一台大型单机上整体运行。
- 资源隔离：可预测的应用程序性能。
- 资源利用：高效率和高密度。

容器云平台



容器云平台是采用容器、容器编排、服务网格、无服务等技术构建的一种轻量化 PaaS 平台。

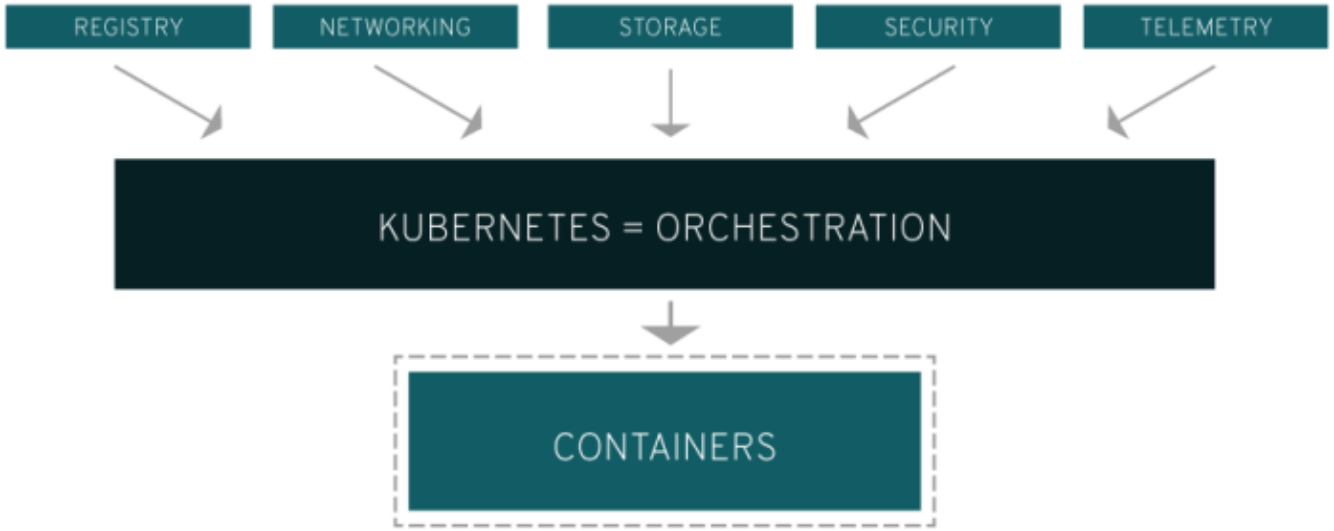
Kubernetes

- Kubernetes是一个管理跨主机容器化应用的系统，是一个容器的编排工具。它实现了包括应用部署、高可用管理和弹性伸缩在内的一系列基础功能，并封装成为一整套完整、简单易用的RESTful API对外提供服务。

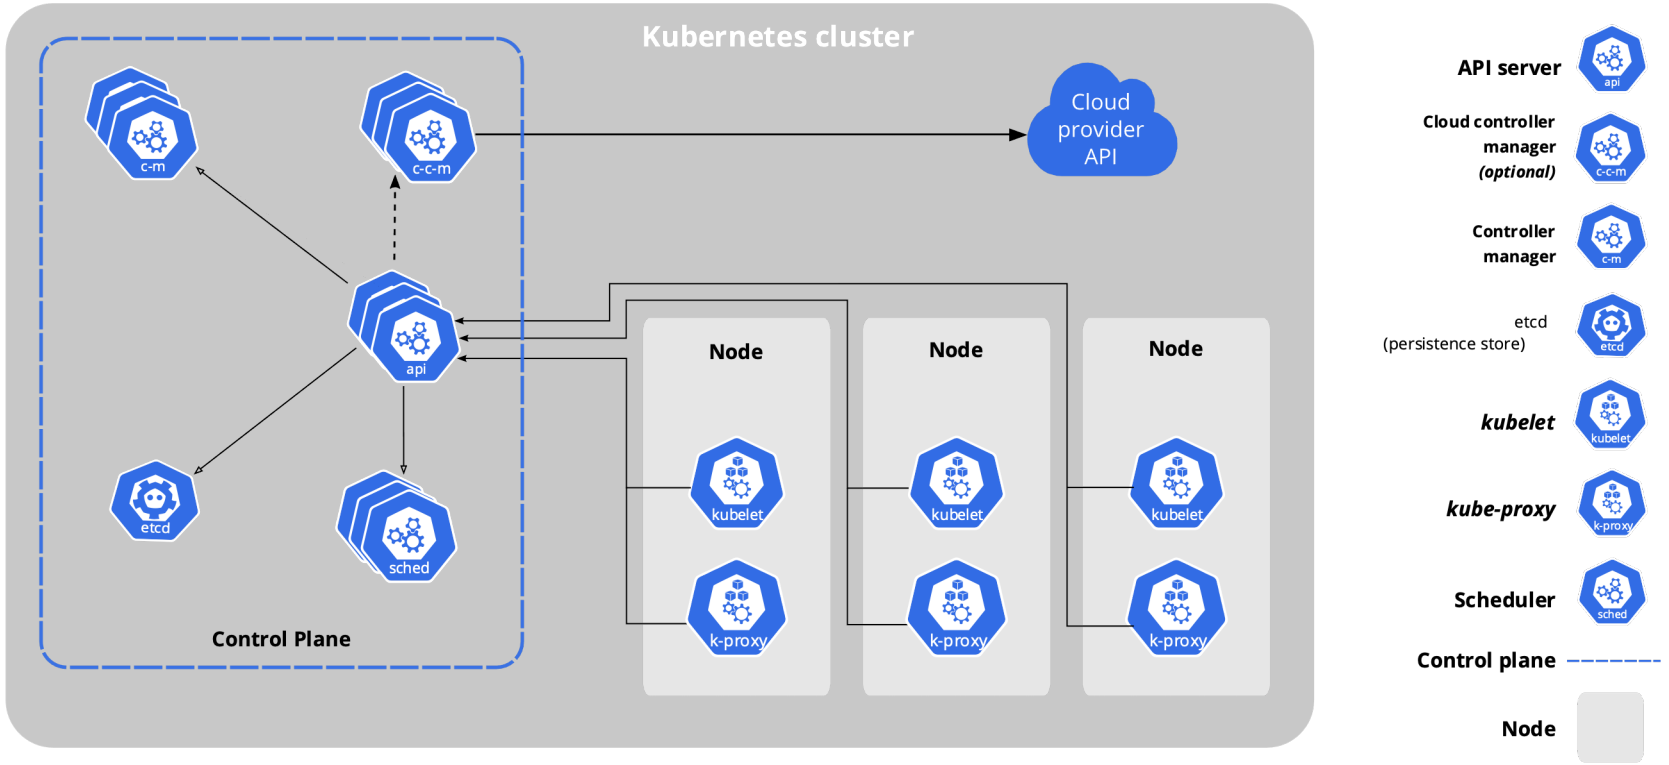


Kubernetes

- 服务发现和负载均衡
- 存储编排
- 自动部署和回滚
- 自动完成装箱计算
- 自我修复
- 密钥与配置管理



Kubernetes

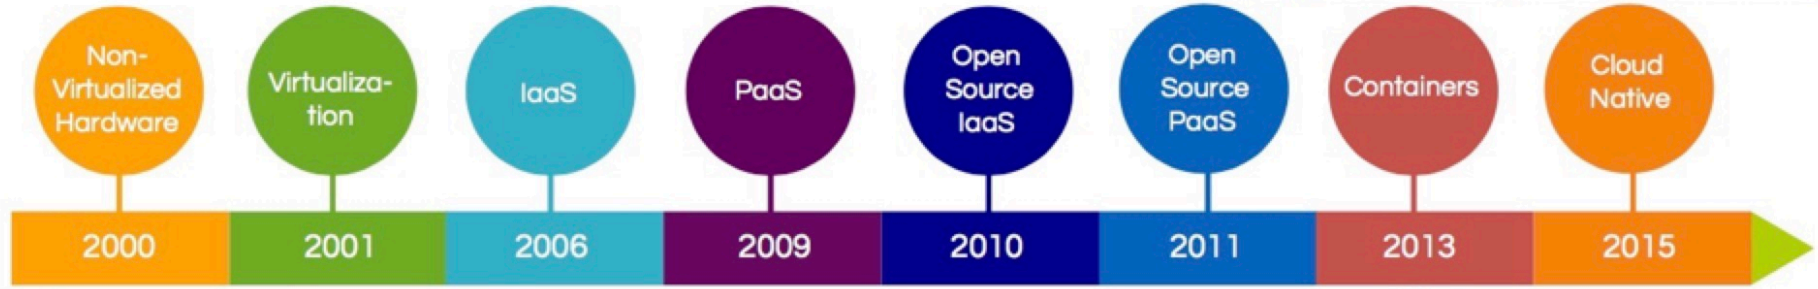

Kubernetes cluster
c-m
c-c-m
Cloud provider API
api
etcd
sched
Control Plane
Node
Node
Node
kubelet
kubelet
kubelet
k-proxy
k-proxy
k-proxy
API server
Cloud controller manager (optional)
Controller manager
etcd (persistence store)
kubelet
kube-proxy
Scheduler
Control plane
Node

云原生

CLOUD NATIVE COMPUTING FOUNDATION

OPEN CONTAINER INITIATIVE

- Cloud native computing uses an open source software stack to:
  - deploy applications as *microservices*,
  - packaging each part into its own *container*
  - and dynamically *orchestrating* those containers to optimize resource utilization
- Standardization: https://www.opencontainers.org/



Sun microsystems vmware amazon web services HEROKU openstack CLOUD SOFTWARE CLOUDFOUNDRY docker CLOUD NATIVE COMPUTING FOUNDATION

CLOUD NATIVE COMPUTING FOUNDATION



云原生

- 云原生是一种构建和运行应用程序的方法，是一套技术体系和方法论。云原生（Cloud Native）是一个组合词，Cloud + Native。

- Cloud表示应用程序位于云中，而不是传统的数据中心；Native表示应用程序从设计之初即考虑到云的环境，原生为云而设计，在云上以最佳姿势运行，充分利用和发挥云平台的弹性+分布式优势。

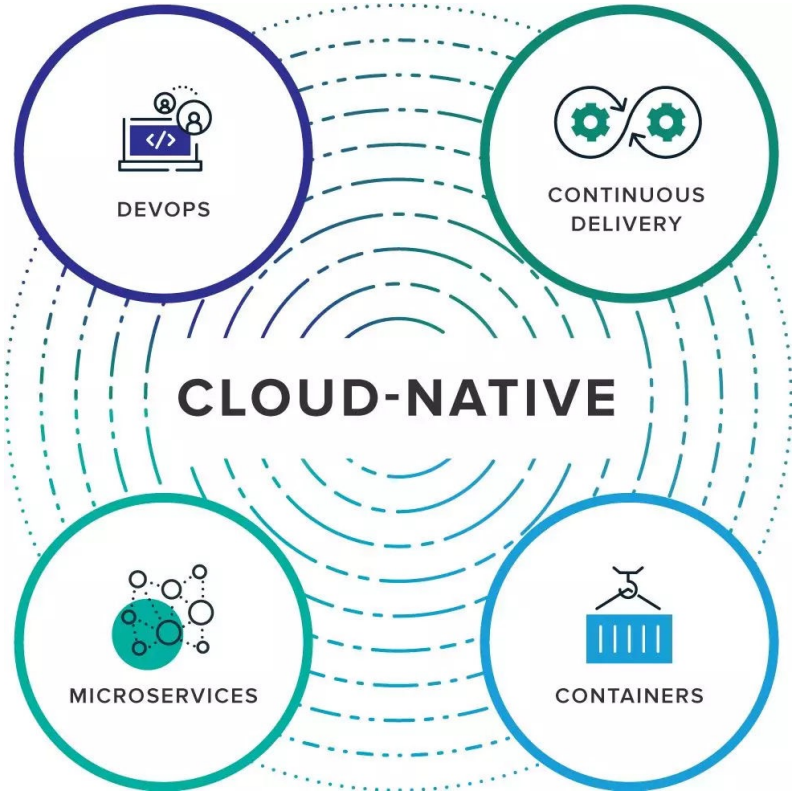


云原生

- 云原生系统需包含的属性：
  - **容器化封装**：以容器为基础，提高整体开发水平，形成代码和组件重用，简化云原生应用程序的维护。在容器中运行应用程序和进程，并作为应用程序部署的独立单元，实现高水平资源隔离。
  - **自动化管理**：统一调度和管理中心，从根本上提高系统和资源利用率，同时降低运维成本。
  - **面向微服务**：通过松耦合方式，提升应用程序的整体敏捷性和可维护性。

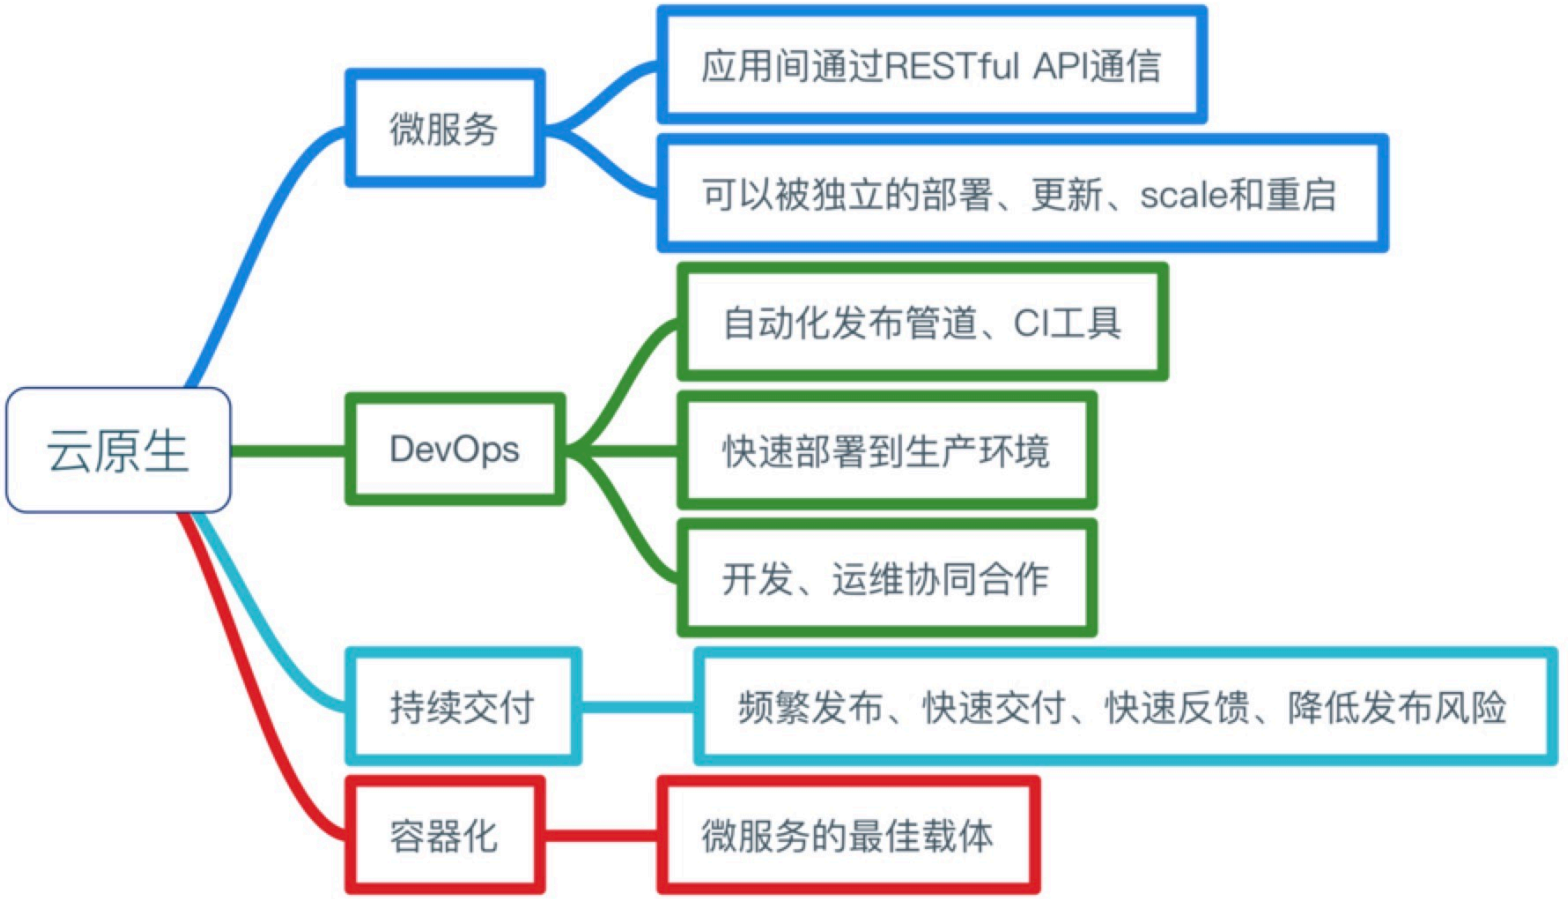
云原生

- 云原生的四要素：持续交付、DevOps、微服务、容器

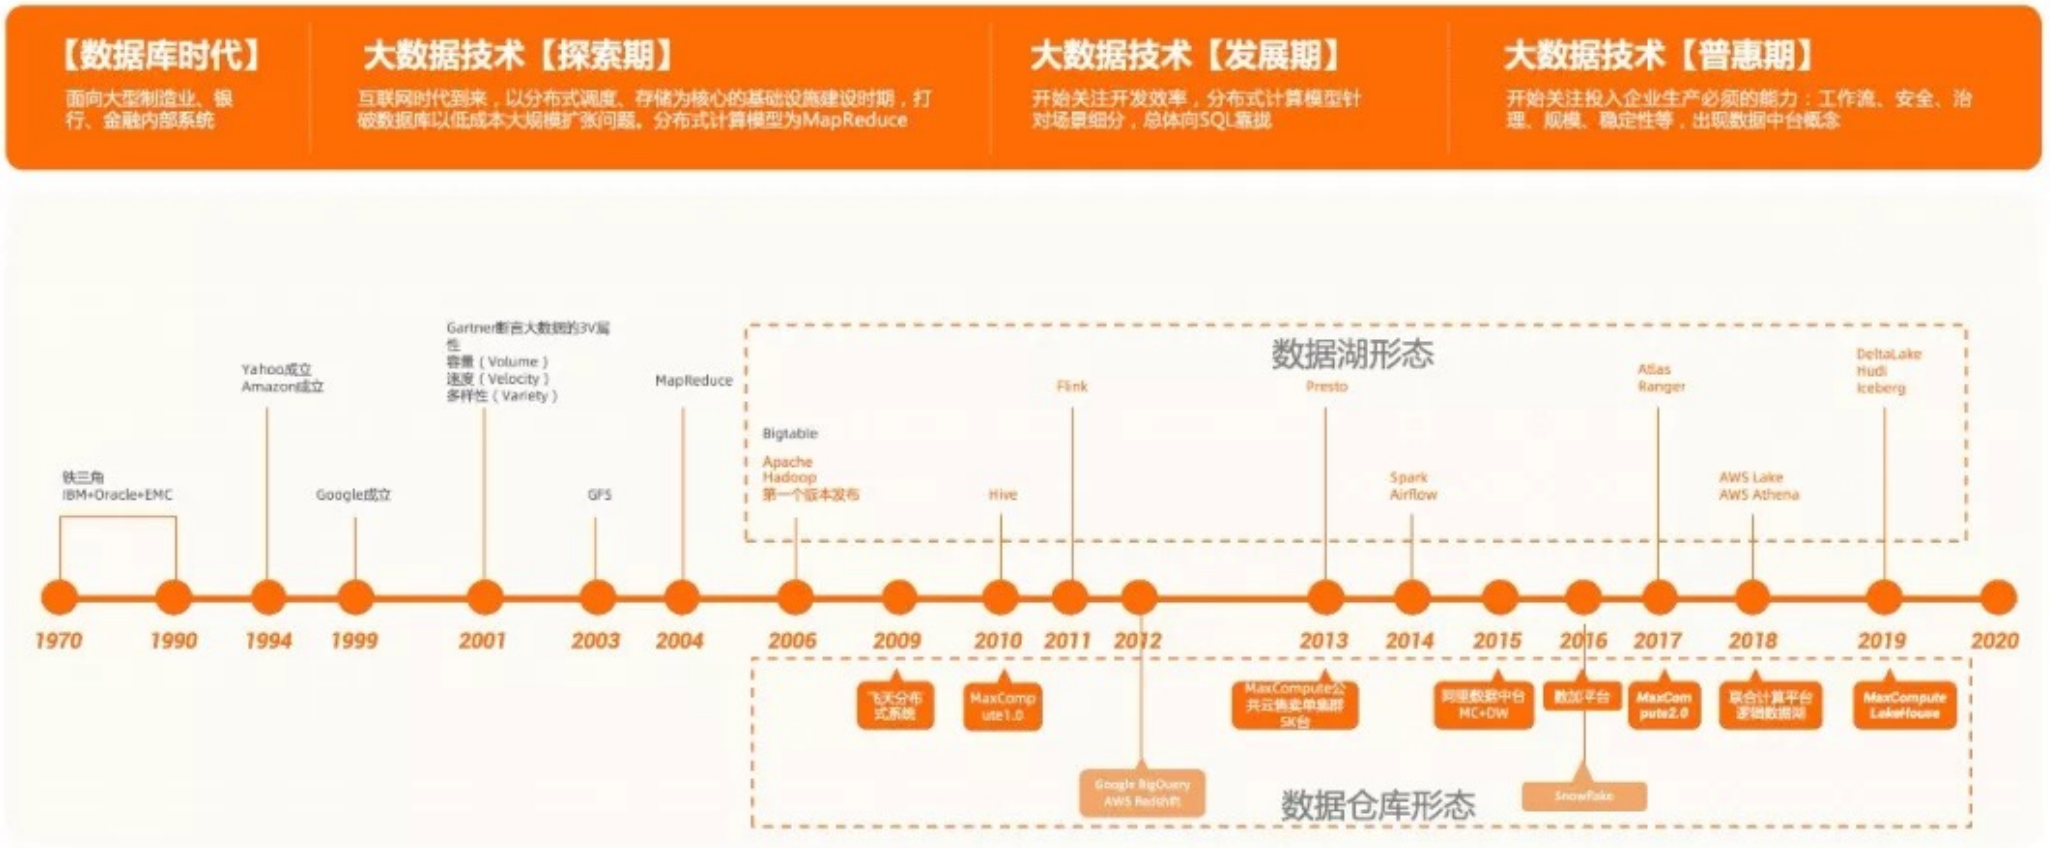




云原生


云原生
微服务
应用间通过RESTful API通信
可以被独立的部署、更新、scale和重启
DevOps
自动化发布管道、CI工具
快速部署到生产环境
开发、运维协同合作
持续交付
频繁发布、快速交付、快速反馈、降低发布风险
容器化
微服务的最佳载体

大数据技术发展路线

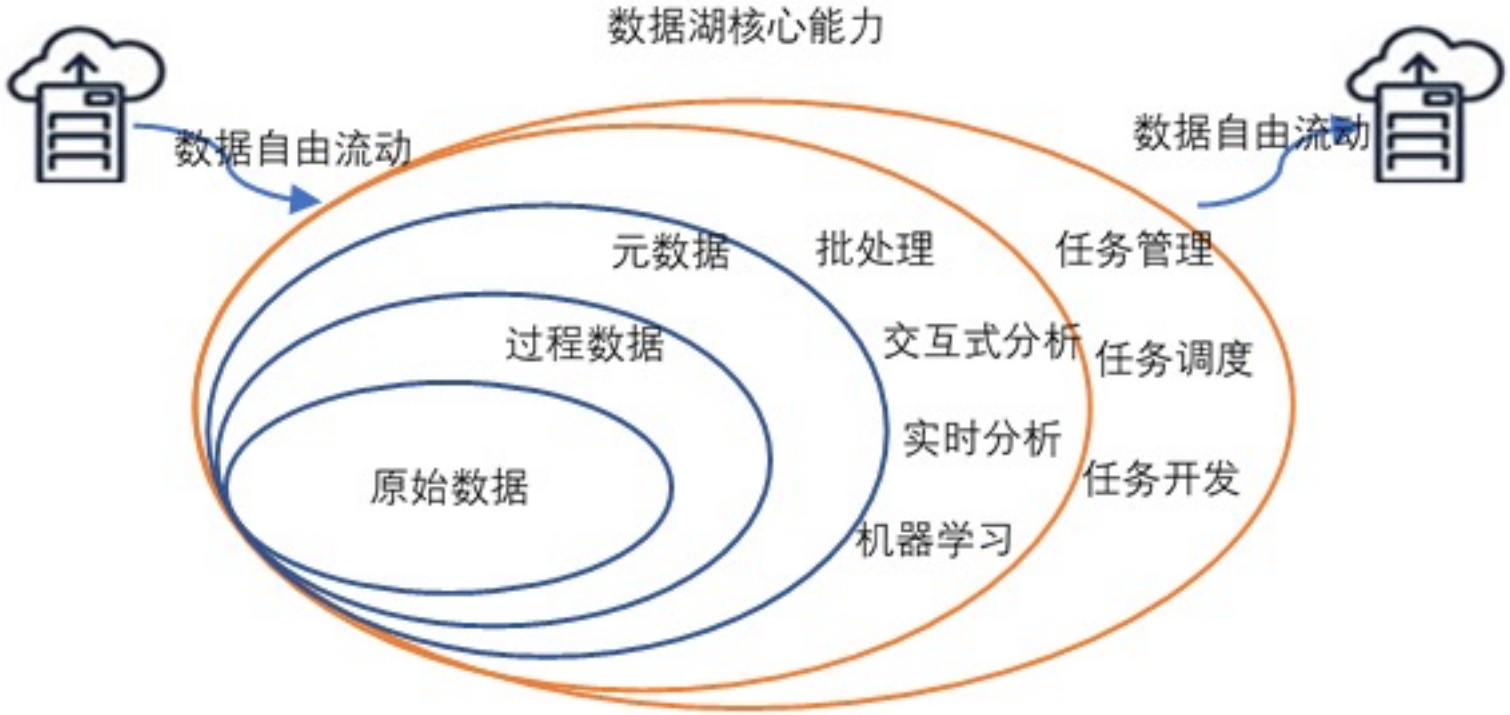

【数据库时代】
面向大型制造业、银行、金融内部系统
大数据技术【探索期】
互联网时代到来，以分布式调度、存储为核心的基础设施建设时期，打破数据库以低成本大规模扩张问题。分布式计算模型为MapReduce
大数据技术【发展期】
开始关注开发效率，分布式计算模型针对场景细分，总体向SQL靠拢
大数据技术【普惠期】
开始关注投入企业生产必须的能力：工作流、安全、治理、规模、稳定性等，出现数据中台概念
铁三角
IBM+Oracle+EMC
Yahoo成立
Amazon成立
Google成立
Gartner断言大数据的3V属性
容量（Volume）
速度（Velocity）
多样性（Variety）
GFS
MapReduce
Bigtable
Apache Hadoop
第一个版本发布
Hive
Flink
数据湖形态
Presto
Spark
Airflow
Atlas
Ranger
AWS Lake
AWS Athena
DeltaLake
Hudi
Iceberg
1970
1990
1994
1999
2001
2003
2004
2006
2009
2010
2011
2012
2013
2014
2015
2016
2017
2018
2019
2020
飞天分布式系统
MaxCompute1.0
Google BigQuery
AWS Redshift
MaxCompute公共云售卖单集群5K台
阿里数据中台MC+DW
数加平台
MaxCompute2.0
联合计算平台
逻辑数据网
MaxCompute Lakehouse
Snowflake
数据仓库形态



数据湖

- Wikipedia
  - 数据湖是一类存储数据自然/原始格式的系统或存储，通常是对象块或者文件。数据湖通常是企业中全量数据的单一存储。全量数据包括原始系统所产生的原始数据拷贝以及为了各类任务而产生的转换数据，各类任务包括报表、可视化、高级分析和机器学习。数据湖中包括来自于关系型数据库中的结构化数据（行和列）、半结构化数据（如CSV、日志、XML、JSON）、非结构化数据（如email、文档、PDF等）和二进制数据（如图像、音频、视频）。

数据湖



数据湖是一种不断演进中、可扩展的大数据存储、处理、分析的基础设施；以数据为导向，实现任意来源、任意速度、任意规模、任意类型数据的全量获取、全量存储、多模式处理与全生命周期管理；并通过与各类外部异构数据源的交互集成，支持各类企业级应用。

数据仓库 vs. 数据湖

数据仓库

- 主要处理历史的、结构化的数据，而且这些数据必须与数据仓库事先定义的模型吻合。
- 处理结构化数据，将它们转化为多维数据或报表，为满足后续的高级报表及数据分析需求。
- 通常用于存储和维护长期数据，数据可以按需访问。

数据湖

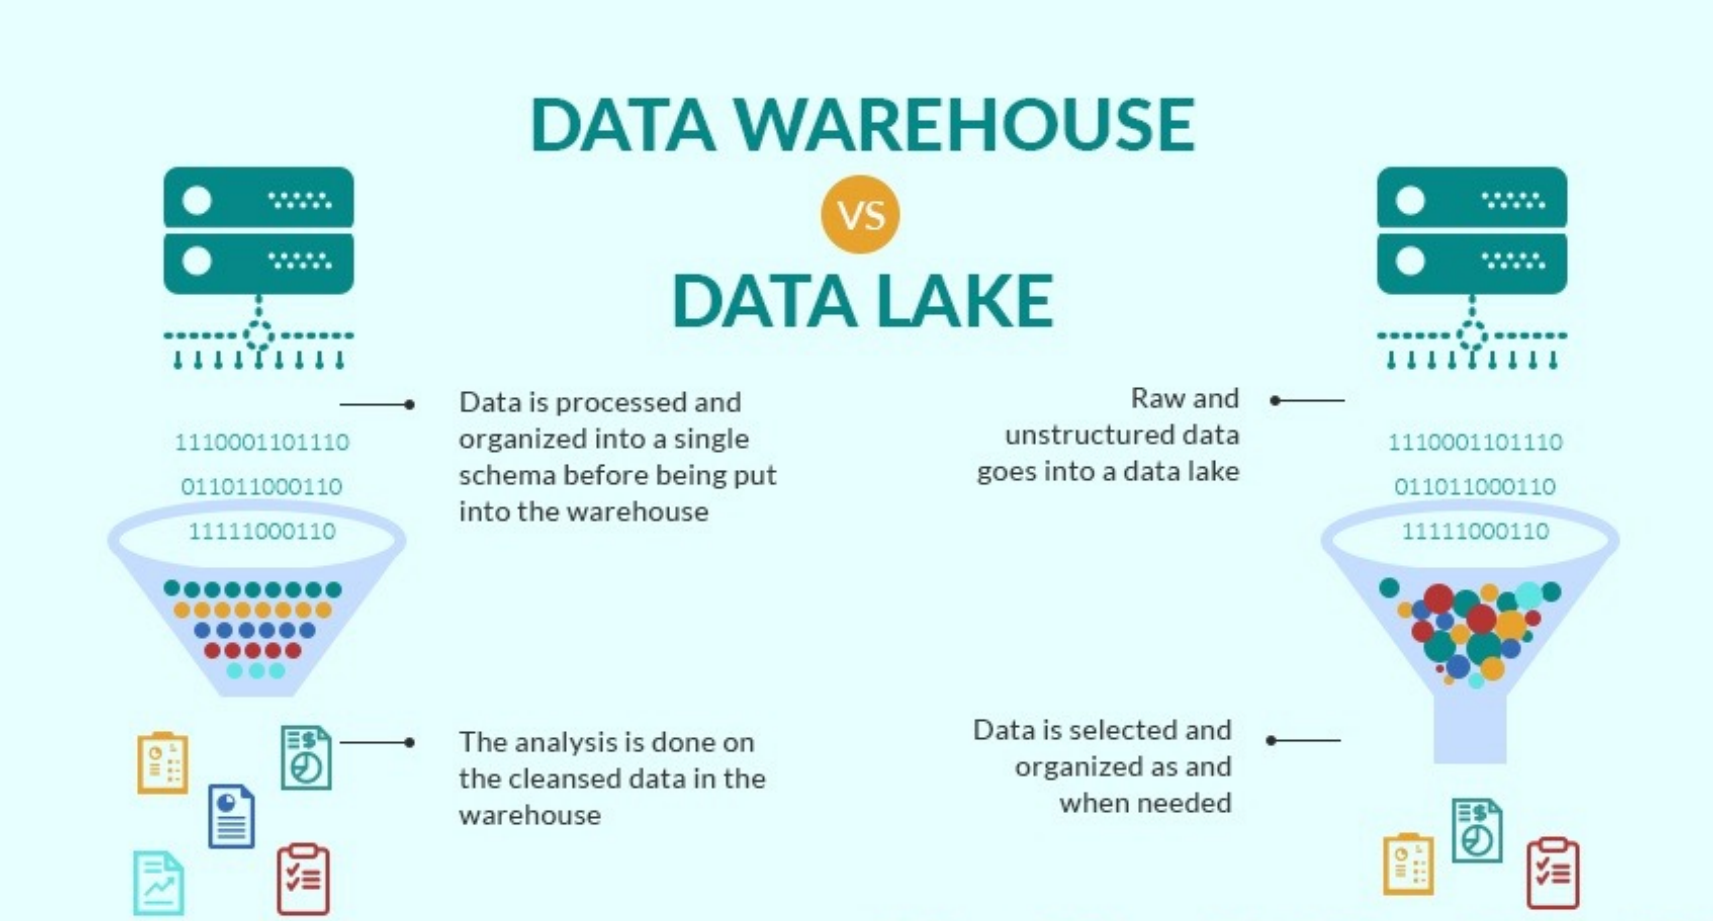
- 能处理所有类型的数据，数据的类型依赖于数据源系统的原始数据格式。
- 拥有足够强的计算能力用于处理和分析所有类型的数据，分析后的数据会被存储起来供用户使用。
- 数据湖通常包含更多的相关的信息，有很高概率会被访问，并且能够为企业挖掘新的运营需求。

数据仓库 vs. 数据湖

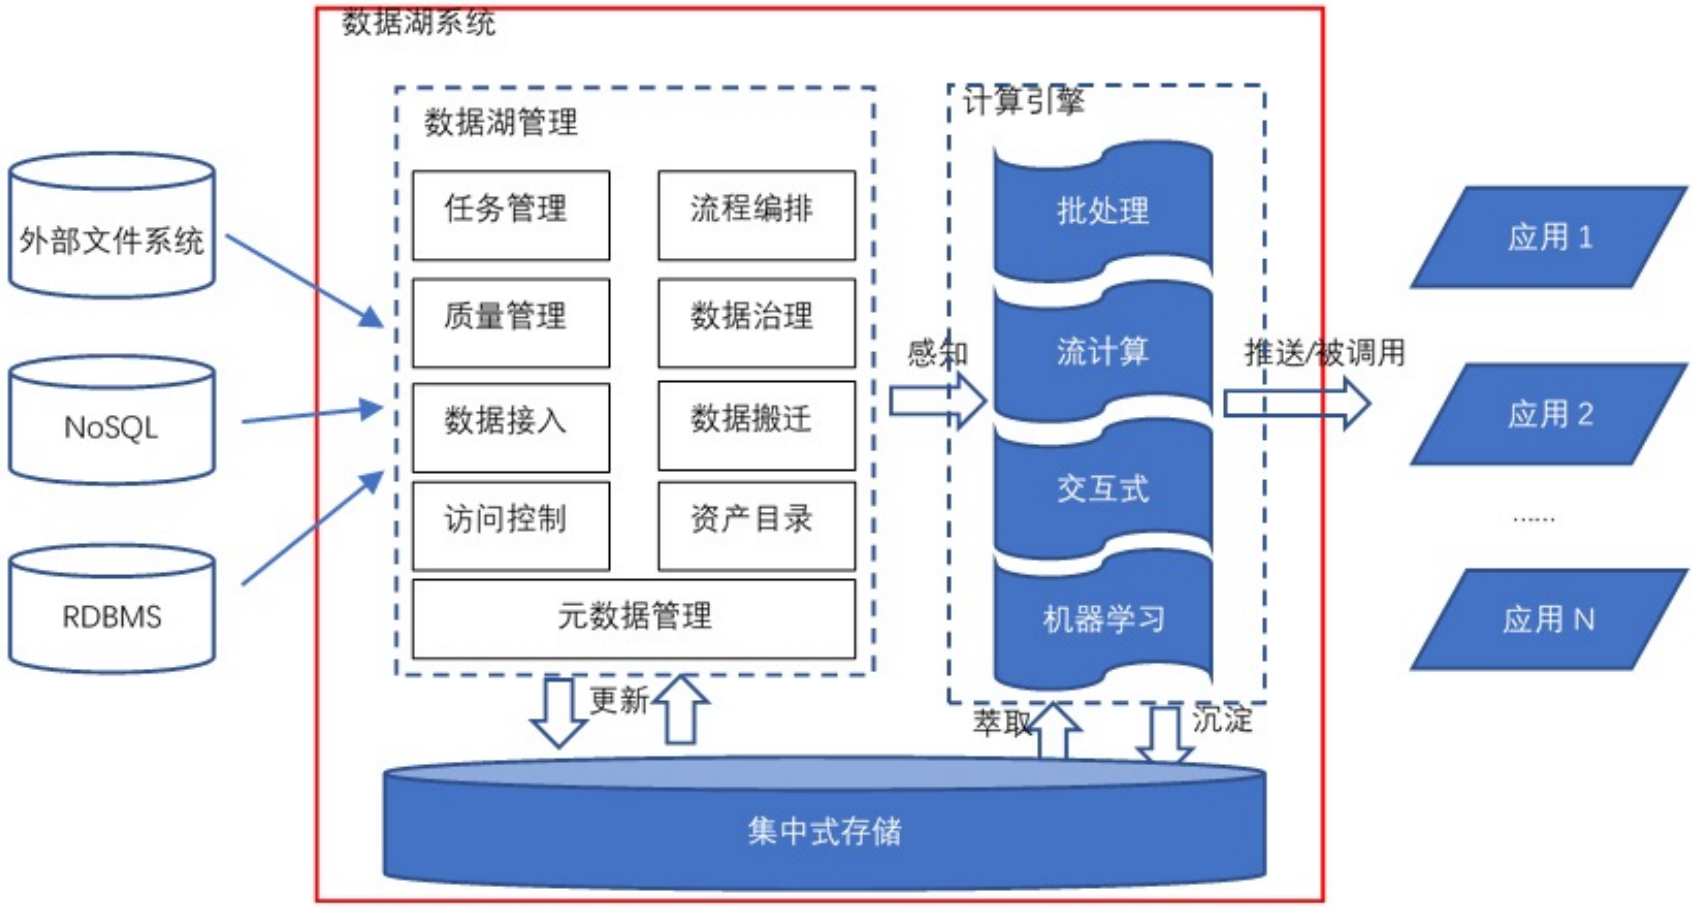
特性	数据仓库	数据湖
数据	来自事务系统、运营数据库和业务线应用程序的关系数据	来自 IoT 设备、网站、移动应用程序、社交媒体和企业应用程序的非关系和关系数据
Schema	设计在数据仓库实施之前（写入型 Schema）	写入在分析时（读取型 Schema）
性价比	更快查询结果会带来较高存储成本	更快查询结果只需较低存储成本
数据质量	可作为重要事实依据的高度监管数据	任何可以或无法进行监管的数据（例如原始数据）
用户	业务分析师	数据科学家、数据开发人员和业务分析师（使用监管数据）
分析	批处理报告、BI 和可视化	机器学习、预测分析、数据发现和分析

保真性、灵活性、可管理、可追溯、丰富的计算引擎、
多模态的存储引擎

数据仓库 vs. 数据湖

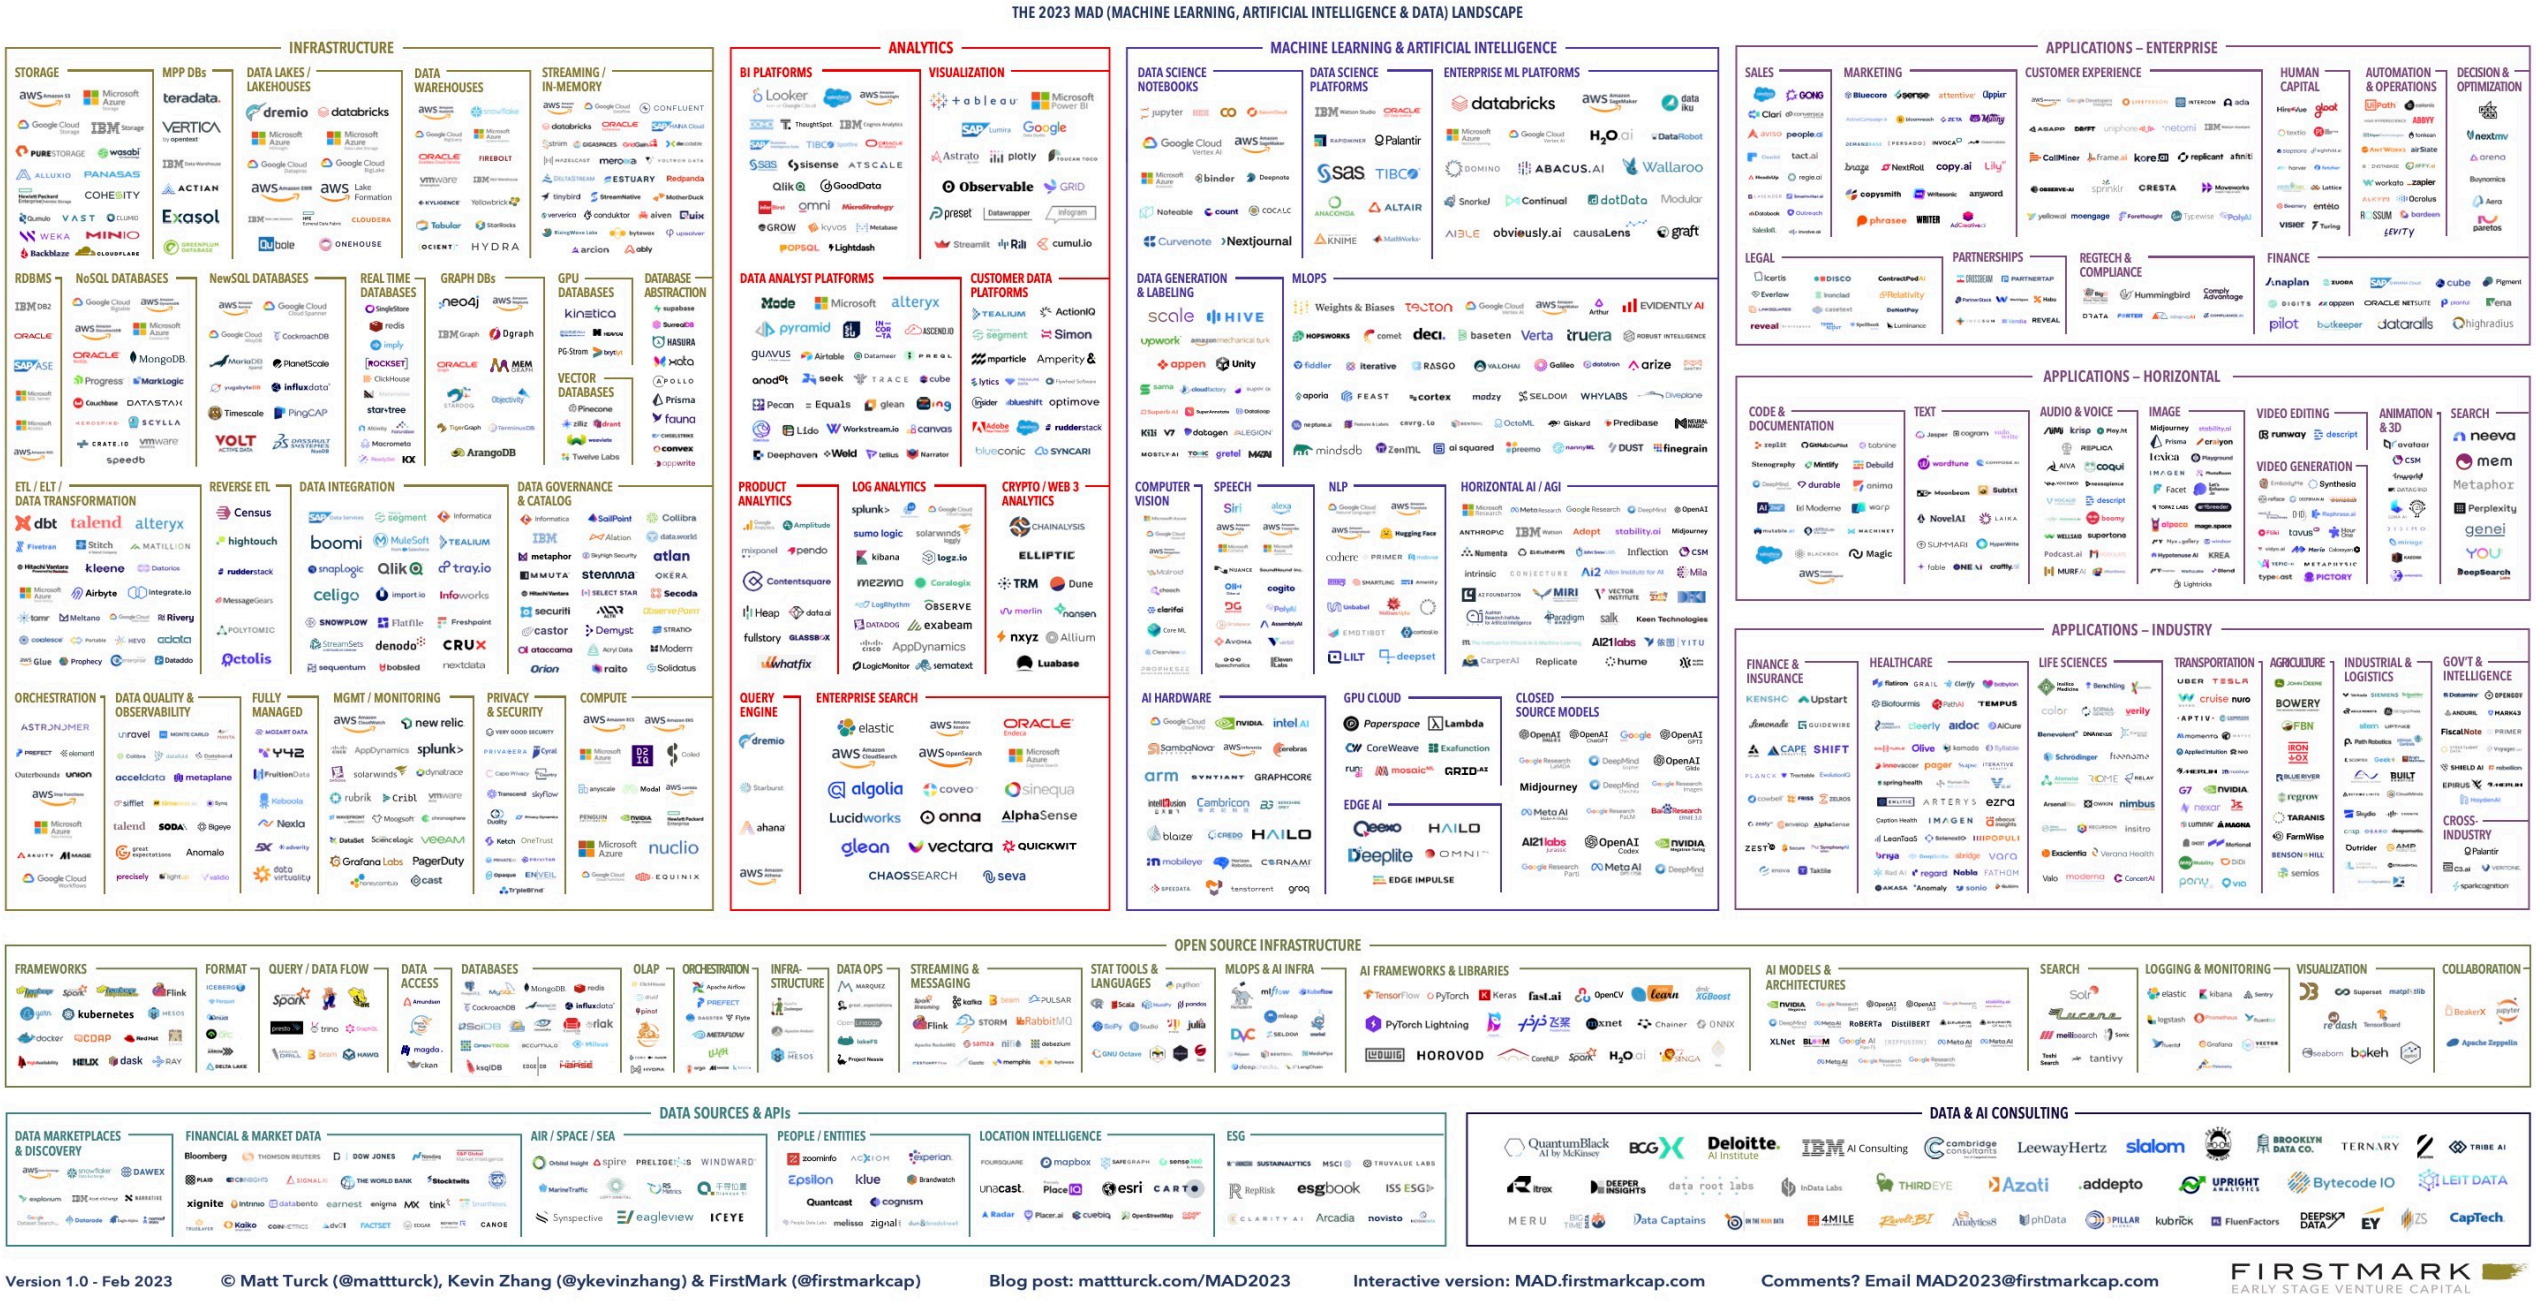

DATA WAREHOUSE
VS
DATA LAKE
Data is processed and organized into a single schema before being put into the warehouse
1110001101110
011011000110
11111000110
The analysis is done on the cleansed data in the warehouse
Raw and unstructured data goes into a data lake
1110001101110
011011000110
11111000110
Data is selected and organized as and when needed

数据湖参考架构


数据湖系统
数据湖管理
任务管理
流程编排
质量管理
数据治理
数据接入
数据搬迁
访问控制
资产目录
元数据管理
外部文件系统
NoSQL
RDBMS
更新
计算引擎
批处理
流计算
交互式
机器学习
感知
推送/被调用
萃取
沉淀
集中式存储
应用 1
应用 2
.....
应用 N

阿里云原生数据湖


数据开发治理
数据开发治理平台 DataWorks
数据源
日志服务
RDS
表格存储
数据传输DTS
云原生计算引擎
EMR
Spark
HIVE
Presto
MaxCompute
Data Lake Analytics
数据湖加速
JindoFS
数据湖构建
数据湖元数据
访问控制
入湖工具
数据湖存储
对象存储OSS
标准 低频 归档
数据湖格式
DELTA LAKE
Apache hudi
ICEBERG



Version 1.0 - Feb 2023 © Matt Turck (@mattturck), Kevin Zhang (@ykevinzhang) & FirstMark (@firstmarkcap) Blog post: mattturck.com/MAD2023 Interactive version: MAD.firstmarkcap.com Comments? Email MAD2023@firstmarkcap.com

FIRSTMARK EARLY STAGE VENTURE CAPITAL

The 2023 MAD (Machine Learning, Artificial Intelligence & Data) Landscape



参考文献

- Nayan B. Ruparelia. Cloud Computing. The MIT Press.
- Thomas Erl，Zaigham Mahmood，Ricardo Puttini. Cloud Computing Concepts, Technology & Architecture.
- 刘鹏，《云计算（第三版）》，电子工业出版社
- 顾炯炯，《云计算架构技术与实践》，清华大学出版社

THANK YOU



南京大學
NANJING UNIVERSITY

南京大学计算机软件研究所
Institute of Computer Software, Nanjing University